

به نام خدا

دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر



درس شبکه‌های عصبی و یادگیری عمیق

پاسخ تمرین شماره یک

دانشجویان:

سوال یک:	علی ممتحن	810104321
سوال دو:	سید احمد رکنی	810104306
سوال سه:	علی ممتحن	810104321
سوال چهار:	سید احمد رکنی	810104306

فهرست

سوال ۱. نورون McCulloch–Pitts 5
۱–۱ منطق آستانه‌ای 5
۱–۲. Majority و Parity 6
سوال ۲. Adaline و Madaline 7
۲–۱. Adaline روی Breast Cancer 7
2-1-1 7
از LMS تا SSE 7
قانون به روزرسانی آنلاین 8
Regularization 8
ارتباط با معادله نرمال 9
2-1-2 10
2-1-3 10
سوال 3. رگرشن با استفاده از mlp 14
1-3 دریافت دیتاست و انجام پیش‌پردازش های لازم 14
2-3 پیاده سازی شبکه عصبی ساده 15
3-3آموزش شبکه عصبی ساده 15
4-3 طراحی و آموزش شبکه عصبی پیچیده تر 17
5-3 مقایسه 18

شکل ها

FIGURE1شکل شبکه دولایه آستانه ای برای XOR 3 ورودی.....6
FIGURE2شبکه آستانه ای برای پیاده سازی تابع MAJORITY.....7
FIGURE 3 محاسبات LMS.....8
FIGURE4محاسبات قانون به روزرسانی آنلاین.....8
FIGURE 5محاسبات REGULARIZATION.....9
FIGURE 6RIDGE شدن L2.....9
FIGURE 7شکل انواع REGULARIZATION.....10
FIGURE 8جداسازی PCA.....11
FIGURE 9 صحت در طول EPOCHS.....12
FIGURE10 در طول SSE EPOCHS.....12
FIGURE11نمودار تغیرات LOSS.....16
FIGURE 12نتایج معیار ها در مدل پیچیده تر.....17
FIGURE13نمودار خطا برای مدل پیچیده.....18
FIGURE14مقایسه پاسخ های پیش بینی شده و پاسخ درست در داده های تست.....19
FIGURE 15میزان LOSS برای داده های تست و آموزش.....20
FIGURE 16نمونه ای از خروجی AUTOENCODER.....20
FIGURE 17 CONFUSION MATRIX برای کلاس ها و خوشه های خروجی ENCODER.....21

جدول‌ها

سوال ۱. نورون McCulloch–Pitts

۱ـ۱ منطق آستانه‌ای

NOT

$w = -1$ و $b = 0.5$

Table 1 جدول درستی not

x	w.x + b	output	True
1	0.5-	0	0
0	0.5	1	0

AND

$w_1 = 0.5$ و $w_2 = 0.5$ و $b = -0.75$

x_1	x_2	w_1.x_1 + w_2.x_2 + b	output	True
1	1	0.25+	1	1
1	0	0.25-	0	0
0	1	0.25-	0	0
0	0	0.75-	0	0

OR

$w_1 = 0.5$ و $w_2 = 0.5$ و $b = -0.25$

جدول 1. جدول درستی not

x_1	x_2	w_1.x_1 + w_2.x_2 + b	output	True
1	1	0.75+	1	1

1	0	0.25+	1	1
0	1	0.25+	1	1
0	0	0.25-	0	0

ضرایب و تاثیرات آن ها در این روش به گونه است که مرز تصمیمی که درست می شود خطی بوده زیرا هر ورودی ضرب در یک ضریب می شود و خروجی از جع اینها درست می شود. این مرز تصمیم خطی در واقع در فضای دو بعدی یک خط و در بالا تر یک ابر صفحه را نشان می دهد که تنها به جدا سازی خروجی هایی منجر می شود که 1 ها در یک سمت صفحه و 0 ها در سمت دیگر قرار گرفته باشند تا بتوان آن ها را جدا کرد.

۱-۲. Majority و Parity

فضای 3 ورودی قسمت parity تشکیل یک فضای 3 بعدی می دهد که ما 8 حالت خروجی به ازای ورودی های مختلف داریم. که در واقع با صفحه مختصات 3 بعدی می توان به آن رسید. شکل آن در واقع یک مکعب است که هر راس آن یا 0 است یا 1. برای اینکه این مسئله با یک نورون آستانه ای قابل نمایش باشد باید بتوان 4 نقطه 1 را با یک صفحه از 4 نقطه 0 جدا کرد. برای اینکه بشود اینکار را کرد باید یا 4 تا 1 روی یک دیواره مکعب باشند که اینطور نیست. زیرا برای اینکه روی یک ضلع باشند باید در تمام خروجی های 1 یکی از مولفه های ورودی مثلا y یک عدد ثابت باشد (زیرا دیوار ها صفحاتی عمود بر هر یک از محور ها هستند). یا باید هر 3 خروجی راسی که خروجی 1 را نشان میدهند با یک ضلع به راس چهارمی که خروجی 1 را نشان میدهد وصل باشند (همین طور برای راس های با خروجی 0) درحالیکه وقتی روی یک ضلع حرکت میکنیم در واقع یکی از مولفه ها را داریم معکوس (not) می کنیم که باعث می شود عدد خروجی عوض شود و این حالت رخ نخواهد داد. در نتیجه هیچ صفحه با این ویژگی وجود ندارد. و نمی توان به صورت خطی عملیات جدا سازی را انجام داد.

در شکل پایین همانطور که مشاهده می شود شبکه دولایه برای xor کشیده شده است. که در آن در همه جا تتا برابر 0 در نظر گرفته شده و باياس هر نود مشخص شده است. در لایه پنهانی نود بالایی مشخص می کند که مجموع ورودی ها حداقل 1 باشد. نود وسط مشخص می کند که حداکثر مجموع برابر 1 باشد که این دوشرط با هم باید باعث تولید 1 در خروجی شود. نود پایینی هم مشخص میکند که مجموع ورودی ها حداقل 3 باشد که این به تنهایی باعث می شود خروجی 1باشد. حداقل 3 نود در لایه میانی لازم است تا بتوان این تابع را پیاده سازی کرد.

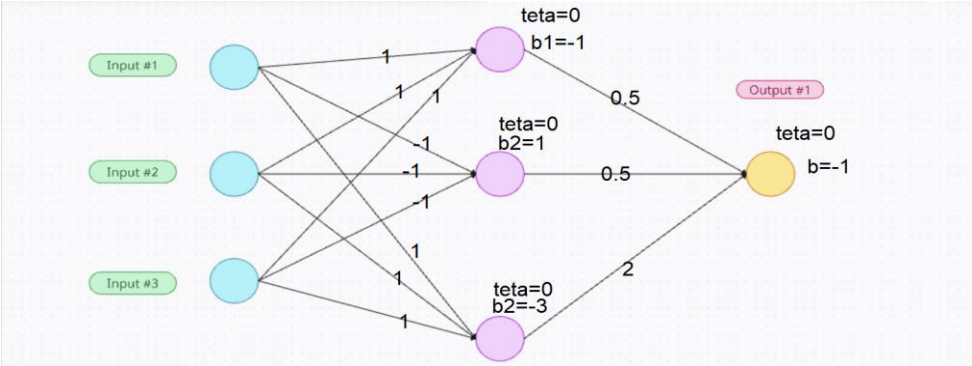


Figure 1شکل شبکه دولایه آستانه ای برای 3 xor ورودی

برای پیاده سازی تابع Majority از یک لایه استفاده می شود و یک لایه برای پیاده سازی آن کافی است. زیرا کافی است مجموع ورودی ها از 3 بزرگ تر مساوی باشد تا بتوان اکثریت را تشخیص داد.

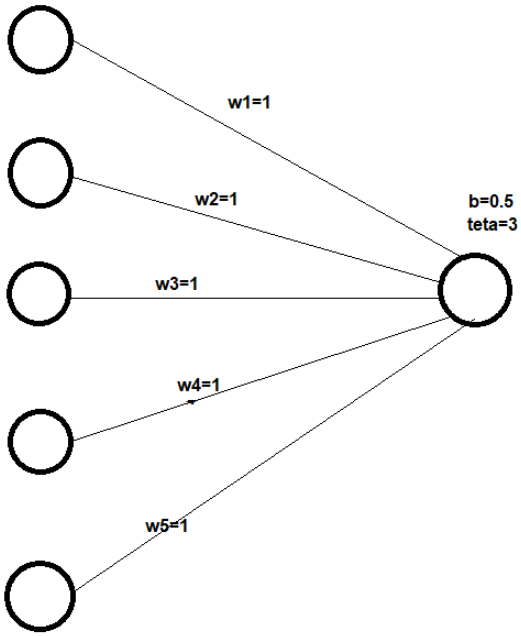


Figure 2شبکه آستانه ای برای پیاده سازی تابعmajority

سوال ۲. Adaline و Madaline

۲-۱. Adaline روی Breast Cancer

2-1-1

از SSE تا LMS

محاسبات مربوط به قانون به‌روزرسانی دسته ای LMS در زیر آمده است

$$W = \begin{bmatrix} w_1 \\ w_2 \\ \dots \\ w_n \end{bmatrix}; X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ .. & .. & \dots & .. \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{bmatrix}$$

$$net = XW + b; \quad O = net - Target;$$

$$SSE = O^T O \Rightarrow SSE = (\text{net} - T)^T (\text{net} - T);$$

$$\frac{\partial net}{\partial W} = X^T;$$

Figure 3 محاسبات LMS

از آنجایی که net = XW + b پس ما داریم

∂SSE/∂W = 2XT (net − T).

و از آنجایی که b به صورت مساوی به همه نمونه ها اضافه می شود پس می توانیم فرض کنیم که X آن برابر 1 است

∂SSE/∂b = 21T (net − T).

با توجه به محاسبات بالا قانون به روزرسانی نهایی به صورت زیر می شود

W[new] = W[old] − αXT (net − T),

b[new] = b[old] − α1T (net − T).

قانون به روزرسانی آنلاین

برای به روزرسانی برای هر نمونه داریم

$$\text{net}_i = x_i^T W + b,$$

$$W_+ = W_- - \alpha x_i (\text{net}_i - t_i),$$

$$b_+ = b_- - \alpha (\text{net}_i - t_i).$$

Figure 4محاسبات قانون به روزرسانی آنلاین

Regularization

ما برای اینکه ضرایب هیچ کدام زیاد بزرگ نشوند (حذف نشوند، فقط بزرگ نشوند) به SSE عبارت مربوط به L2 Regularization را اضافه می کنیم

محسابات مربوط به آن در زیر آمده است

$$L2 = \lambda W^T W; \quad SSE_{reg} = O^T O + L2 \quad \Rightarrow \quad SSE_{reg} = O^T O + \lambda W^T W$$

$$\frac{\partial SSE_{reg}}{\partial W} = \frac{\partial SSE}{\partial W} + \frac{\partial L2}{\partial W}$$

$$\frac{\partial SSE_{reg}}{\partial W} = 2X^T(net - Target) + 2\lambda W$$

$$\frac{\partial SSE_{reg}}{\partial W} = \alpha(X^T(net - Target) + \lambda W)$$

Figure 5محاسبات Regularization

که در نهایت قانون آپدیت به صورت زیر در می آید

$$W[new] = W[old] - \alpha(X^T (net - T) + \lambda W)$$

ارتباط با معادله نرمال

ما با 0 قرار دادن گرادیان می توانیم فرم بسته جواب ridge را به دست آوریم

$$(X^T X + \lambda I)W = X^T T \quad \Rightarrow \quad W = (X^T X + \lambda I)^{-1} X^T T.$$

Figure 6ridge شدن L2

که این مورد نشان می دهد اضافه کردن عبارت 2L باعث می شود که ضرایب خیلی بزرگ نشوند

به صورت شهودی هم به وسیله شکل زیر می توان دیدی که از آنجایی که عبارت 2L برخلاف منظم ساز 1L که عبارتش به صورت قدر مطلقی است و شکلی مانند لوزی درست می کند، عبارت 2L معادله دایره است.

و این معادله دایره با بهینه ساز در نقاطی برخورد می کند که نقاط گوشه ای آن نیستند که هر کدام از ضرایب (در زیر 2theta 1, theta را) صفر کنند، بلکه در موقعیتی برخورد می کنند که هیچ کدام صفر نیستند و فقط کوچک شده اند.

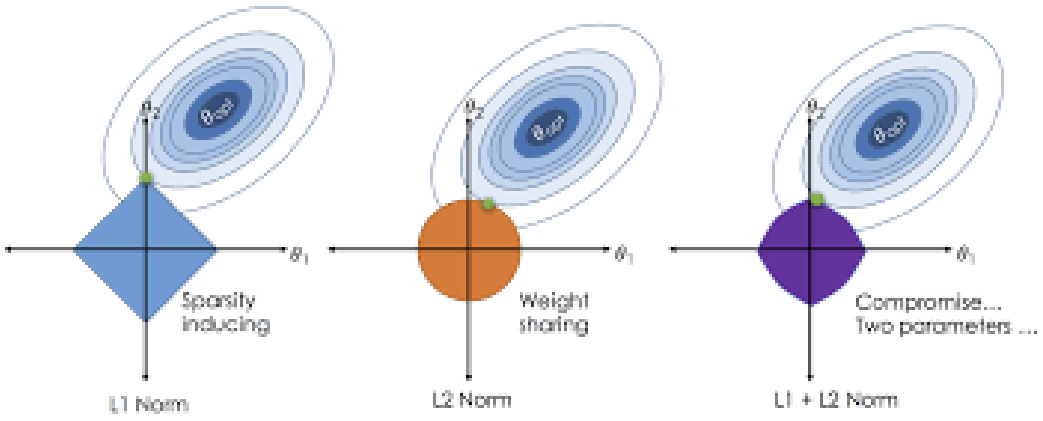


Figure 7 شکل انواعregularization

2-1-2

کدهای مربوط به این بخش در فایل کد مربوط به سوال 2 موجود است

2-1-3

	Actually positive	Actually Negative
Predicted Positive	53	10
Predicted Negative	2	106

Accuracy	0.9298245614035088
Precision	0.9137931034482759
Recall	0.9814814814814815

F1-Score	0.9464285714285714

مرز تصمیم خطی Adaline در PCA

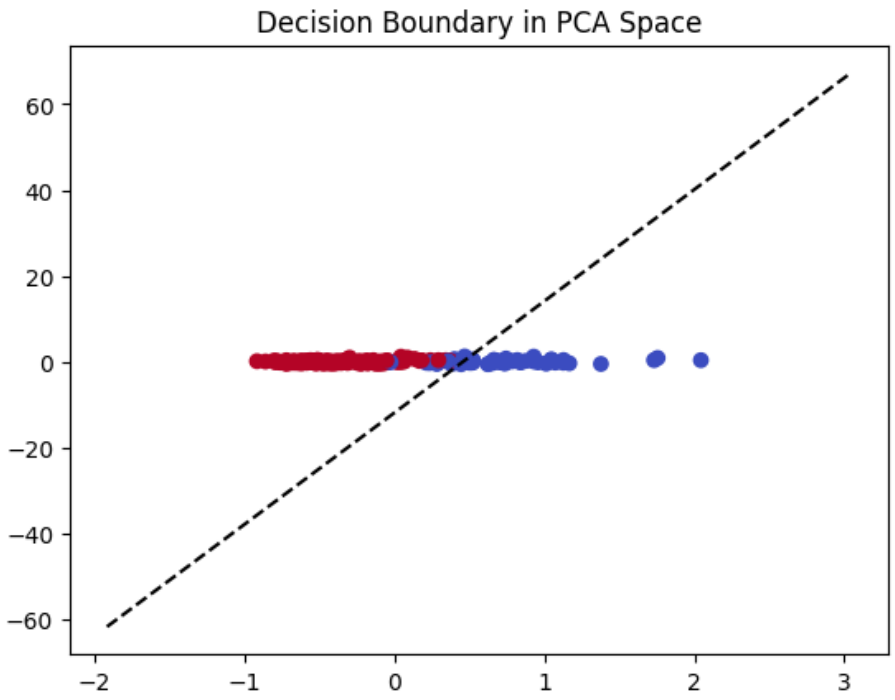


Figure 8جداسازی PCA

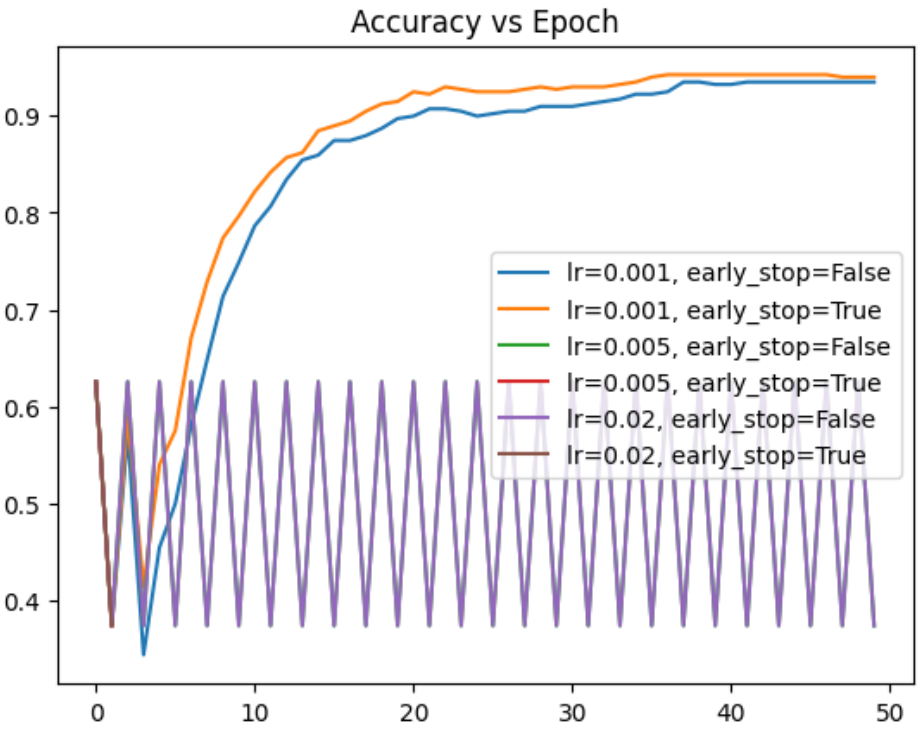
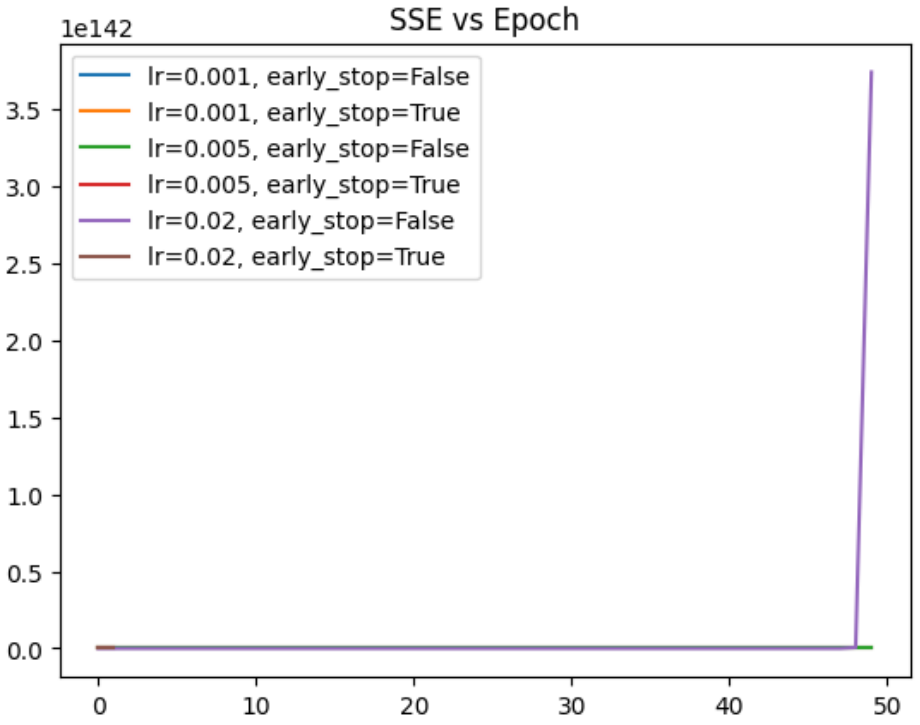


Figure 9 صحت در طول epochs



SSE10 Figureدر طول epochs

معیار	Logistic Regression	LDA	Adaline
نوع مدل	احتمالاتی (Discriminative)	احتمالاتی (Generative)	خطی (Deterministic)
تابع تصمیم	سیگموید از ترکیب خطی ویژگی‌ها	ترکیب خطی ویژگی‌ها با فرض توزیع گاوسی	تابع خطی بدون سیگموید
فرض آماری	ندارد (مدل فقط بر مرز تصمیم تمرکز دارد)	فرض نرمال بودن کلاس‌ها و کوواریانس برابر	بدون فرض آماری
خروجی	احتمال تعلق به هر کلاس	احتمال از طریق مدل گاوسی	مقدار پیوسته (برای طبقه‌بندی باید آستانه بگذاریم)
حساسیت به نویز	متوسط	نسبتاً پایین در صورت صحت فرض‌ها	زیاد
پیچیدگی محاسباتی	پایین	پایین	پایین
نیاز به داده زیاد	متوسط	نیاز به داده برای برآورد توزیع‌ها	پایین
عملکرد روی داده‌های غیرخطی	ضعیف (مگر با kernel)	ضعیف	ضعیف
قابلیت تفسیر	بالا	متوسط	بالا (ولی نه احتمالاتی)

اگر داده‌ها تقریباً خطی و کم نویز باشند، Adaline می‌تواند مشابه Logistic Regression عمل کند ولی با همگرایی سریع تر چون یادگیری‌اش ساده‌تر است.

اما اگر داده‌ها correlation یا نویز بالا داشته باشند، Logistic Regression یا LDA معمولاً بهترند چون خروجی احتمالاتی دارند و تصمیماتشان نرم‌تر است

اگر داده ها هم توزیع نرمال داشته باشند که LDA از همه بهتر عمل می کند

در آخر هم در داده‌های غیرنرمال یا وقتی که مرز تصمیم دقیقاً خطی نیست، Logistic Regression نسبت به LDA و Adaline عملکرد بهتری دارد

2-2-2

برای تصاویر ماه

	Real Positive	Real Negative
Predicteed Positive	88	4
Predicteed Negative	32	56

برای تصاویر دایره

	Real Positive	Real Negative
Predicteed Positive	92	0
Predicteed Negative	88	0

تمام اطلاعات مربوط به loss برای سایر در کد وجود دارد

سوال 3. رگرشن با استفاده از mlp

1-3 دریافت دیتاست و انجام پیش‌پردازش های لازم

در این قسمت پیش پردازش داده ها انجام شده است. برای قسمت مدیریت missing value ها برای ستون های عددی از استراتژی میانه استفاده شده است. دلیل این انتخاب این است که این معیار در برابر داده های پرت (outliers) مقاوم است. همچنین برای داده های categories که تنها ستون آن ocean_proximity بود از استراتژی بیش ترین تکرار استفاده شده است. دلیل این جایگزینی به طور کلی این است که چون اندازه ورودی به ازای تمام داده ها ثابت است باید مقداری در جای این ستون ها باشد تا مدل در هنگام اجرا و آموزش دچار ارور نشود. و انتخاب میانه به عنوان این جایگاه باعث می شود که تاثیر این ستون خالی در نتیجه مدل کمینه شده و از تا حدی از بین برود.

برای حذف outlier از IQR استفاده شده است. که در این روش اختلاف چارک اول و سوم را در نظر میگیریم و به اندازه 1.5 برابر آن را نسبت به این دو چارک مرز حذف داده ها outlier درنظر می گیریم. علت حذف داده های پرت از مدل این است که این داده ها باعث می شود در دنیای واقعی مدل پیش بینی نا درستی داشته باشد زیرا این داده ها از حالت نرمال خارج شده اند و تاثیر آن ها روی مدل باعث خطای مدل در برسی دیگر داده های عادی می شود.

فیچر های categories را نیز که در این دیتاست تنها یکی بوده است را به صورت onehot انکود کرده‌ایم. به این معنا که 5 ورودی به مسئله اضافه شده است که هرکدام اگر 1 شود یعنی این ستون یک دسته خاص را در آن فیچر داشته است.

2-3 پیاده سازی شبکه عصبی ساده

شبکه عصبی ساخته شده در کد موجود میباشد. تعداد پارامتر های این شبکه عصبی برابر 121 محاسبه شده است.

3-3آموزش شبکه عصبی ساده

توضیحات هرکدام از معیار ها:

-MSE:

این معیار برابر میانگین مربعات اختلاف بین مقادیر واقعی و پیش بینی شده است. این معیار در برابر داده های outlier حساس است اما محاسبه آن آسان و مشتق پذیر است. برای آموزش دادن در مدل های ساده مناسب است.

$$\sum_{i=1}^{n} \quad \frac{1}{n}(y_i - \hat{y}_i)^2$$

-RMSE:

این معیار در واقع جذر MSE است و واحد آن همان واحد هدف است در نتیجه قابل تفسیر تر است. این معیار هم در برابر outlier ها حساس است و در مواردی که نیاز به یک معیار قابل تفسیر تر برای خطا داریم از آن استفاده می شود.

$$\sqrt{\sum_{i=1}^{n} \quad \frac{1}{n}(y_i - \hat{y}_i)^2}$$

-MAE:

این معیار برابر میانگین قدرمطلق خطا ها است. این برخلاف دومعیار قبلی در برابر داده های outlier حساسیت کمتری دارد اما مشتق پذیر نیست. کاربرد آن در مواردی است که وجود داده های outlier در بین داده ها عادی است.

$$(1/n) * \sum \quad |y_i - \hat{y}_i|$$

-R2:

این معیار که برای مقایسه مدل های مختلف استفاده می شود به نوعی میزان شباهت نتیجه مدل به توزیع داده ها را نشان می دهد. مقدار معیار کمتر از 1 است هرچه مقدار به 1 نزدیک تر باشد یعنی مدل بهتر بوده مقدار 0 به این معنا است که مدل مانند میانگین داده های آن را پیش بینی می کند و مقدار منفی یعنی مدل از میانگین داده ها هم ضعیف تر است.

$$1 - \frac{\sum_{i=1}^{n} \quad \frac{1}{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} \quad \frac{1}{n}(y_i - \underline{y})^2}$$

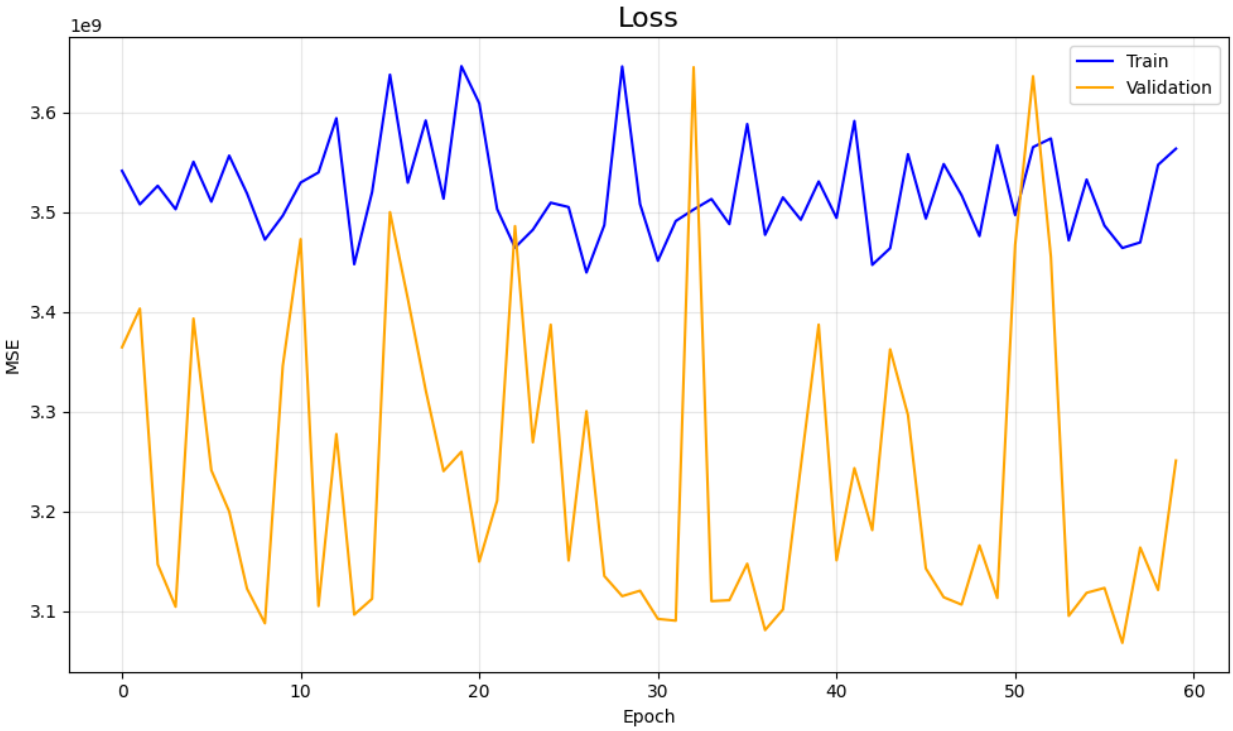
نتایج معیار های خواسته شده در شکل زیر نشان داده شده است.

```
==================================================
total report of train
==================================================
RMSE  : 59,283 $
MSE   : 3,514,505,728
MAE   : 42,323 $
R²    : 0.6081

==================================================
total report of Val
==================================================
RMSE  : 57,017 $
MSE   : 3,250,885,632
MAE   : 41,799 $
R²    : 0.6586

==================================================
total report of test
==================================================
RMSE  : 59,500 $
MSE   : 3,540,273,152
MAE   : 42,619 $
R²    : 0.6098
```

نتایج معیار های خواسته شده روی داده های تست ارزیابی و دیتا



11 Figureنمودار تغیراتloss

4-3 طراحی و آموزش شبکه عصبی پیچیده تر

شبکه عصبی جدید با 4 لایه درست شده است که تعداد پارامتر های آن برابر 415 عدد است که حدود 4 برابر شبکه عصبی ساده در قسمت قبل است. همچنین در این شبکه عصبی لرنینگ ریت برابر 0.01 قرار داده شده و بعد از دو لایه از Batch Norm استفاده شده است که باعث بهتر شدن مدل شده است.

```
==================================================
total report of train
==================================================
RMSE  : 49,429 $
MSE   : 2,443,274,496
MAE   : 35,355 $
R²    : 0.7307

==================================================
total report of Val
==================================================
RMSE  : 48,290 $
MSE   : 2,331,944,960
MAE   : 35,027 $
R²    : 0.7551

==================================================
total report of test
==================================================
RMSE  : 49,900 $
MSE   : 2,490,047,488
MAE   : 35,520 $
R²    : 0.7223
```

Figure 12نتایج معیار ها در مدل پیچیده تر

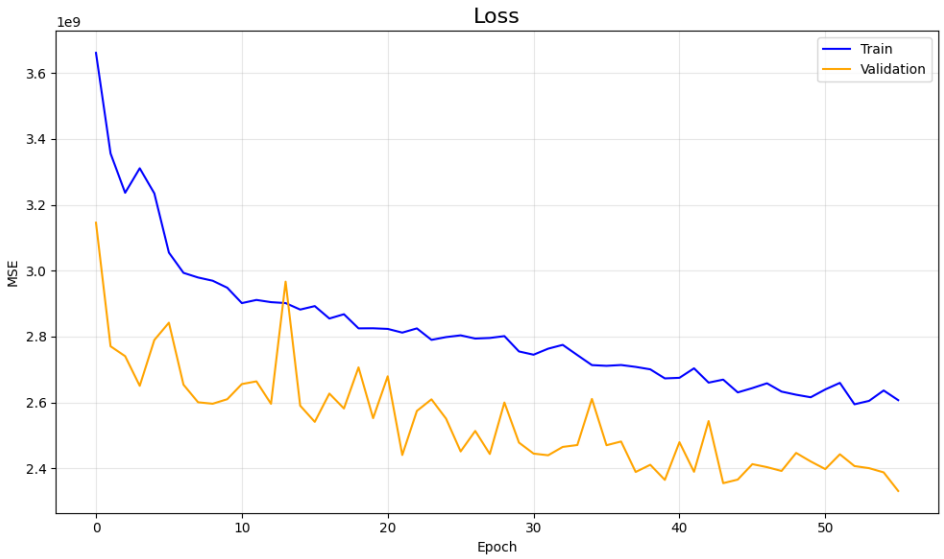


Figure 13نمودار خطا برای مدل پیچیده

5-3 مقایسه

با مقایسه نمودار خطا در هر دو مدل این نتیجه حاصل می شود که فرآیند کاهش خطا در مدل پیچیده تر بسیار روان تر و بهتر از مدل ساده حاصل شده است و سینوسی بودن مدل ساده نشان می دهد که تعداد پارامتر ها به نوعی برای مدل سازی داده ها کافی نیستند و یا لرنینگ ریت زیاد است و مانع روند نزولی در فرآیند می شود.

در مقایسه معیار ها در مدل ها میبینیم که مدل پیچیده تر در هر 4 معیار گفته شده و در هر 3 بخش تست ارزیابی و آموزش بسیار بهتر از مدل ساده عمل کرده است که نشان دهنده بهینه شدن کامل مدل بعد از تغیرات است.

در شکل زیر هایپرپارامتر ها باهم دیگر مقایسه شده اند.

مقایسه هایپرپارامترها بین دو مدل

هایپرپارامتر	شبکه عصبی پیچیده	شبکه عصبی ساده
تعداد لایه	4 با اضافه شدن 2 تا BatchNorm	2
Optimizer	Adam	Adam
Batch Size	64	64
Learning Rate	0.01	0.1
Loss Function	MSE	MSE

همانطور که مشاهده می شود تنها هایپرپارامتر های عوض شده لرنینگ ریت و تعداد لایه های مدل است که باعث شدند معیار ها بسیار افزایش پیدا کنند اما این ها به تنهایی نتوانستند معیار R^2 را در همه 3 بخش به بالای 0.7 برسانند. اما با اضافه شده BatchNorm این معیار در تمامی بخش ها به بالای 0.7 رسید. این بدلیل این است که با نرمالایز کردن خروجی هر بخش فرآیند آموزش علاوه بر سریع تر شدن بسیار بهتر انجام می شود و از درست شدن وزن های بزرگ جلوگیری می شود که باعث بهتر شدن مدل می شود.

همچنین نمودار actual vs predicted در شکل زیر نمایش داده شده است

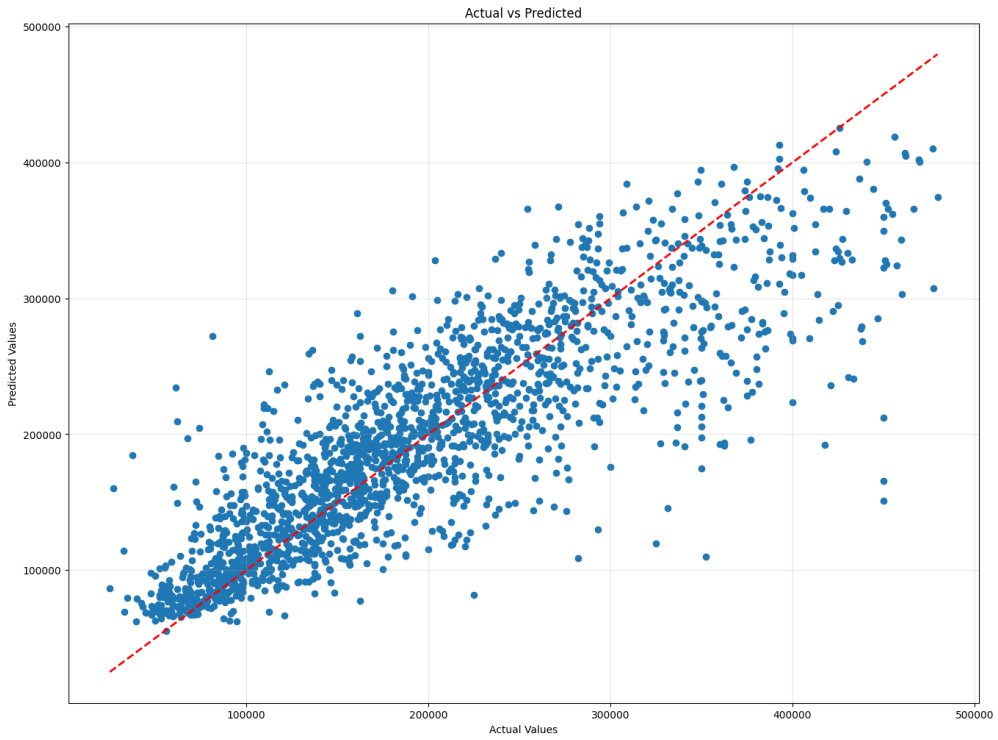


Figure 14مقایسه پاسخ های پیش بینی شده و پاسخ درست در داده های تست

سوال 4

4-1

پیاده سازی مربوط به این سوال در فایل ... آمده است

4-3

در زیر نمودار loss برای داده های آموزش و تست آمده است

همچنین تنها یکی نمونه از عکسی که توسط encoder ساخته شده است در زیر آمده است و مابقی عکس ها در فایل مربوط به این سوال موجود می باشند

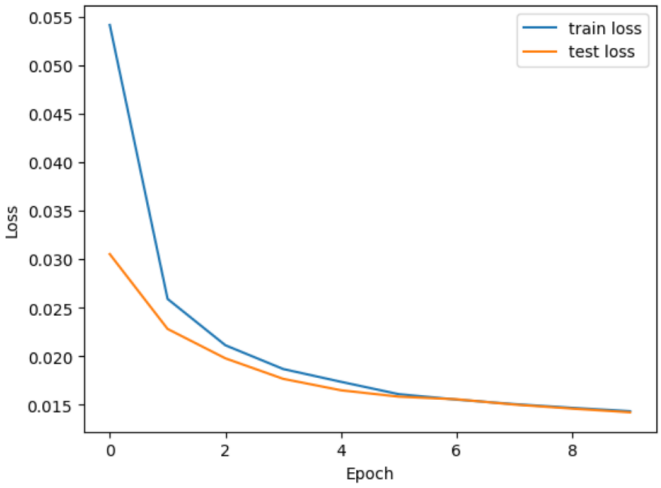


Figure 15میزان lossبرای داده های تست و آموزش

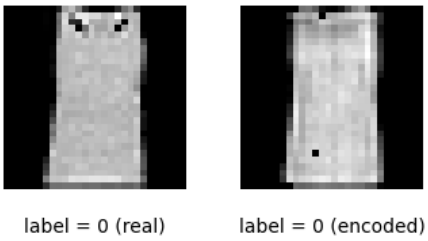
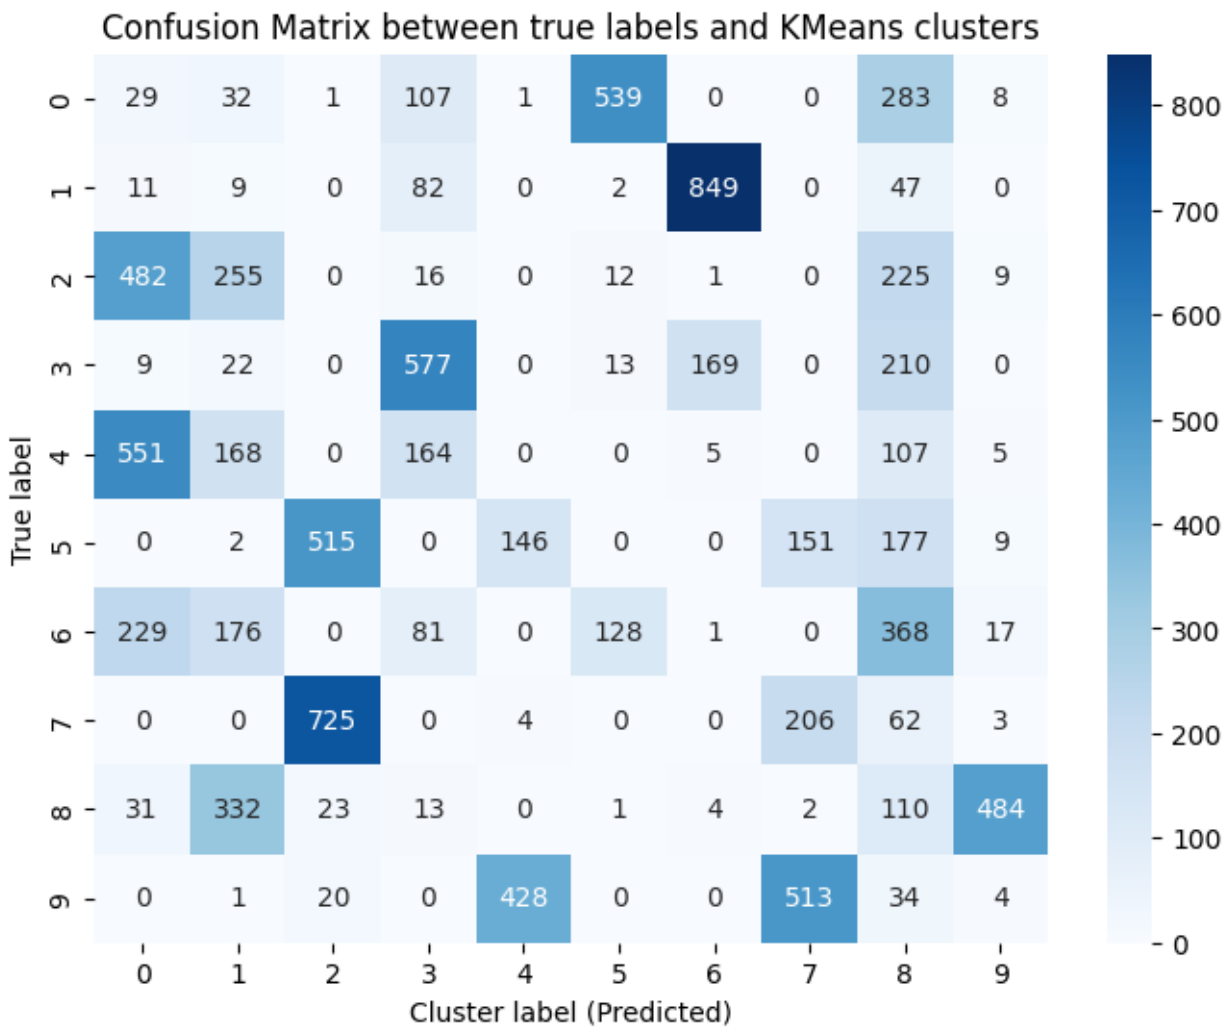


Figure 16نمونه ای از خروجی AutoEncoder

4-4

4-4-3

در زیر Confusion Matrix برای کلاس ها و خوشه ها آمده است.



Confusion matrix 17 Figure برای کلاس ها و خوشه های خروجی encoder

بیشترین کلاس برای هر خوشه در جدول زیر آمده است

خوشه Cluster))	بیشترین تعداد در کلاس واقعی	تعداد بیشینه	کلاس احتمالی
0	کلاس 4 (551)	551	**کلاس 4**
1	کلاس 8 (332)	332	**کلاس 8**
2	کلاس 7 (725)	725	**کلاس 7**
3	کلاس 3 (577)	577	**کلاس 3**
4	کلاس 9 (428)	428	**کلاس 9**
5	کلاس 5 (146)	146	**کلاس 5**
6	کلاس 9 (513)	513	**کلاس 9** (دوباره)
7	کلاس 1 (849)	849	**کلاس 1**
8	کلاس 6 (368)	368	**کلاس 6**
9	کلاس 8 (484)	484	**کلاس 8**

برخی کلاس ها که با سبز مشخص شده اند به خوبی و به درستی تفکیک شده اند

اما سایر کلاس ها دارای درهم ریختگی می باشند

از آنجایی که کلاس‌هایی مثل 4، 6 و 8 در چند خوشه پخش شده‌اند نتیجه می گیریم که ویژگی ها دارای هم پوشانی در این فضا می باشند.

	Raw	Encoded
ARI	0.3804757125830626	0.37981651187250426
AMI	0.5168095879551529	0.5444582718134177

از افت شاخص ARI متوجه می شویم که خوشه‌ها از نظر هم‌پوشانی برچسبی منظم‌ترند در داده خام نسبت به AutoEncoder

اما از بیشتر شدن AMI متوجه می شویم وابستگی که اطلاعاتی بین خوشه‌ها و کلاس‌ها در فضای AutoEncoder بیشتر است

در نتیجه AutoEncoder باعث افزایش حفظ ساختار اطلاعاتی (AMI) شده، اما در جداسازی دقیق‌تر کلاس‌ها (ARI) تأثیر خاصی نداشته.