



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه عصبی

پاسخ تمرین شماره سه

سید احمد رکنی حسینی - ۸۱۰۱۰۴۳۰۶

علی ممتحن - ۸۱۰۱۰۴۳۲۱

فهرست مطالب

فهرست تصاویر ۳

فهرست جداول ۴

۱ سوال یک ۵

۱—۱ آماده‌سازی مجموعه داده ۵

۱—۱—۱ تحقیق و توضیح ۵

۱—۱—۲ مصور سازی داده‌ها ۸

۱—۲ پیاده سازی مدل ۸

۱—۳ متریک ها ۸

۱—۴ آموزش مدل ۱۲

۱—۵ مصور سازی نتایج ۱۳

۲ سوال دو ۱۴

۲—۱ سوالات نظری ۱۴

۲—۲ مجموعه داده ۱۵

۲—۳ آپیاده سازی مدل ۱۵

۲—۴ آموزش مدل ۱۶

۲—۵ ارزیابی مدل و مصورسازی نتایج ۱۷

فهرست تصاویر

۱ ایجاد تصاویر sagittal و axial در کد ۶
۲ آموزش بر مبنای patch ۷
۳ تصاویر مغز بیمارها ۹
۴ آموزش بر مبنای patch ۱۰
۵ تعریف متریک ها ۱۱
۶ نمودار dice و loss در ایپاک ها ۱۲
۷ خروجی مدل در کنار عکس های اصلی ۱۳
۸ نمونه باکس بندی داده ها ۱۵
۹ نمودار تغیرات خطا و دقت در فرآیند آموزش روی داده های آموزش ۱۶
۱۰ نمودار تغیرات خطا و دقت در فرآیند ارزیابی ۱۶
۱۱ نمونه خروجی مدل بعداز آموزش ۱۷

فهرست جداول

۱ تعریف متریک ها ۱۱
۲ خروجی آخرین ایپاک مدل ۱۲

۱ سوال یک

۱–۱ آماده‌سازی مجموعه داده

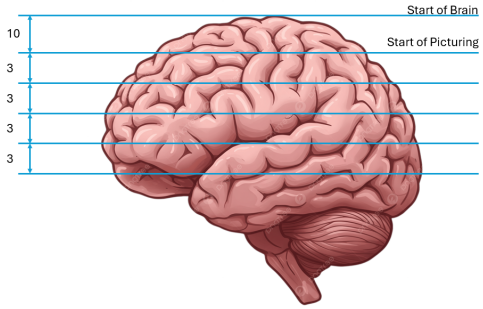
۱–۱–۱ تحقیق و توضیح

ابتدا به توضیح کد $HW3 - Q1 - dataprep.py$ که برای استخراج عکس های دو بعدی از حجم سه بعدی اسکن شده داده شده است می پردازیم.

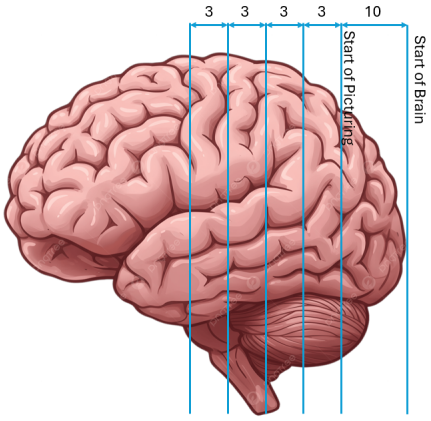
کلیت کار این کد این است که از یک اسکن مغزی به ازای هر نوع ،coronal axial و sagittal ۴۸ عکس تولید می کند.

نحوه پیاده سازی عکس برداری آن نیز در شکل ۱ آمده است.

همانطور که مشخص است عکس برداری از فریم ۱۰ شروع می شود و با استراید ۳ جلو می رود. ۴۸ تصویر اولی که به این روش به دست می آیند تصاویر هدف ما هستند. برای این عکس برداری از فریم ۱۰ شروع شده است که تصاویر سیاه فریم های ابتدایی حذف شوند.



Axial (آ)



Sagittal (ب)

شکل ۱ : ایجاد تصاویر sagittal و axial در کد

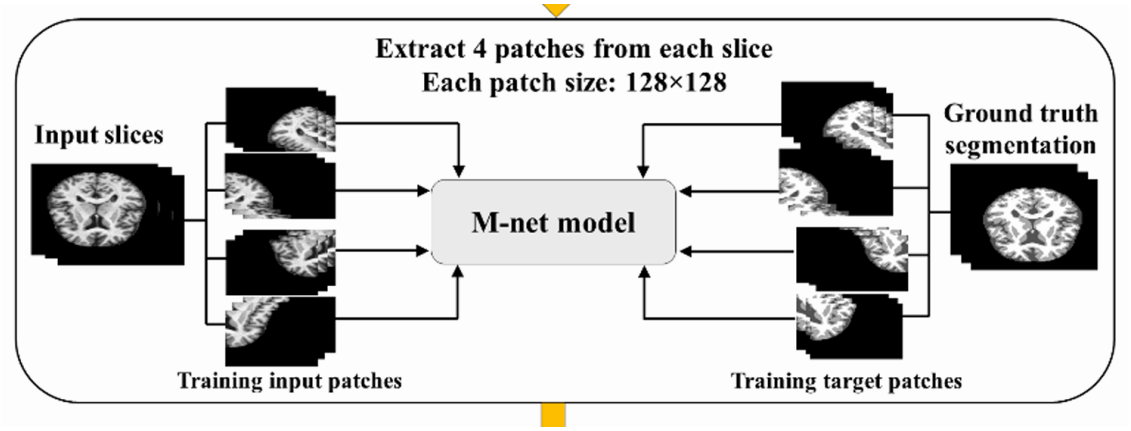
پس از انتخاب تصاویر مورد نظر، باید همه آن ها را هم اندازه کرد. تابع pad_slice با دادن پدینگ سیاه به تصاویر آن ها را به ابعاد 256×256 تبدیل می کند.

در انتهای عکس های به دست آمده را به ۴ قسمت تقسیم می کنیم و در آرایه های patches و masks می ریزیم.

عکس های بدون لیبل را در آرایه patches و داده لیبل گذاری شده در masks ذخیر شده اند.

ابعاد اولیه تصاویر با فرمت nii هم برابر (۲۵۶، ۱۲۸، ۲۵۶، ۱) است.

در انتها لازم است توضیحی هم در رابطه با آموزش بر مبنای patch ها بدهم. در این روش ما یک عکس را به چند قسمت تقسیم می کنیم و هر قسمت را جدا گانه به مدل می دهیم تا آموزش ببیند. کلیت این مدل در شکل ۲ آمده است. این patch ها ممکن است با هم اشتراک داشته باشند یا مثل مدلی که در این تمرین در



شکل ۲: آموزش بر مبنای patch

پیش گرفته ایم با هم اشتراکی نداشته باشند. در اینجا ما هر تصویر را تقسیم به ۴ patch کرده ایم و به مدل داده ایم.

استفاده از روش آموزش بر مبنای patch مزایایی دارد که عبارتند از :

- مدل روی الگوهای محلی متمرکز می شود و آن ها را یاد می گیرد. در تصاویری مانند تصاویر مغز که این الگوهای محلی مهم است، استفاده از این روش باعث بهبود مدل می شود.
- رجاهایی که ما دیتای کمی داریم استفاده از این روش سبب می شود که بتوانیم از هر عکس تعداد زیادی عکس تولید کنیم و دیتای خود را برای آموزش مدل افزایش دهیم
- در مواردی که عکس ها بزرگ اند و هر عکس حجم زیادی دارد با این روش می توان رم GPU مصرف شده را کاهش داده و روند یادگیری را بهبود داد.

در مقاله مورد اول و دوم دلایل اصلی ای بودند که برای استفاده از این روش ذکر شده اند.

اما استفاده از این روش معایبی هم دارد که به شرح زیر اند :

- از آنجایی که تصاویر به بخش های کوچک تقسیم شده اند، مدل الگوهای کلی را نمی تواند به خوبی یادبگیرد.
- مدل الگوهای محلی که در مرز patch ها قرار دارند را نمی تواند خوب یادبگیرد، زیرا الگو بین دو تصویر متفاوت تقسیم شده است. البته می توان با ایجاد overlap بین تصاویر این مورد را کاهش داد.

۱–۱–۲ مصور سازی داده‌ها

شکل ۳ نشان دهنده تصاویر مغز سه بیمار هست.

شکل ۴ هم نشان دهنده تصویر پچ ها هست که کنار هم قرار گرفته اند. هر ۴ پچ کنار هم رسم شده اند که شکل اصلی را نیز تداعی می کند.

.

۱–۲ پیاده سازی مدل

مدل شامل سه بخش می باشد که هر کدام کاربرد مخصوص خودشان را دارند :

- Encoder : استفاده از این ساختار سبب باعث می شود که مدل ویژگی های ابسترکت تری را بیاموزد و نگاه کلی تری به patch ها داشته باشد. این موارد سبب می شود که مدل الگوهای بزرگ تر را بهتر شناسایی کند.
- Connections Skip : این قسمت و leg ها شامل دیتاهای جزئی، با کیفیت بالاتر و غیر ابسترکت هستند.
- Decoder : قسمت Decoder با استفاده از هر دو قسمت بالا هم الگوهای کلی و هم الگوهای جزئی را شناسایی می کند.

در انتها هم عکس را بازسازی می کند. به این صورت مدل در سطح پیکسل هم همسایگی های جزئی را به خوبی یاد بگیرد و هم الگوهای کلی را، و این دو در کنار هم سبب می شوند که مدل دقت بالایی داشته باشد.

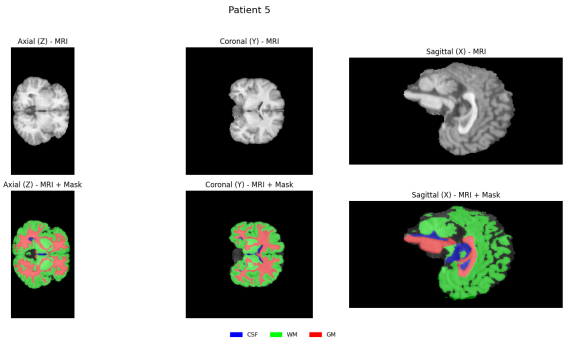
مدل هیچ پارامتر غیر آموزش پذیری ندارد اما دارای ۸،۴۷۹،۶۲۰ پارامتر قابل آموزش می باشد.

۱–۳ متریک ها

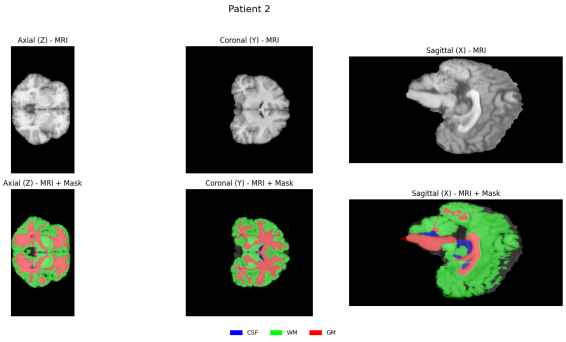
تعریف هریک از متریک ها پیشتر در درس آمده بوده است که در شکل ۵ نیز نشان داده شده است. همچنین تعریف تمیز تر آن ها نیز در جدول ۱ آمده است.

کاربرد هر کدام از متریک ها

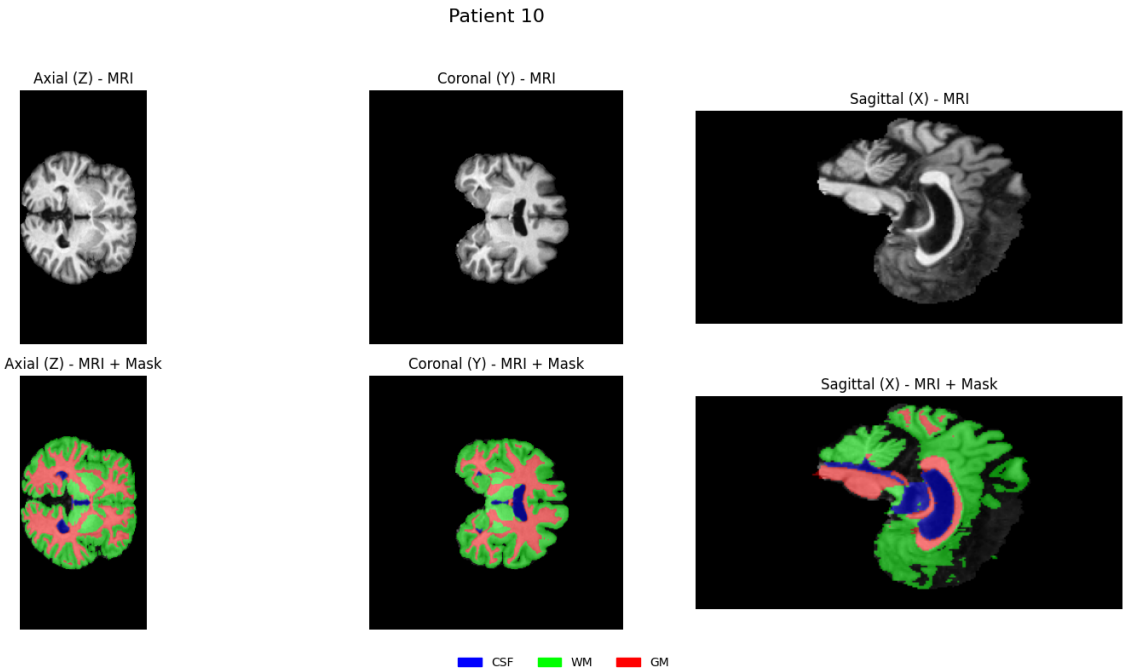
۱ سوال یک



(آ) بیمار ۵



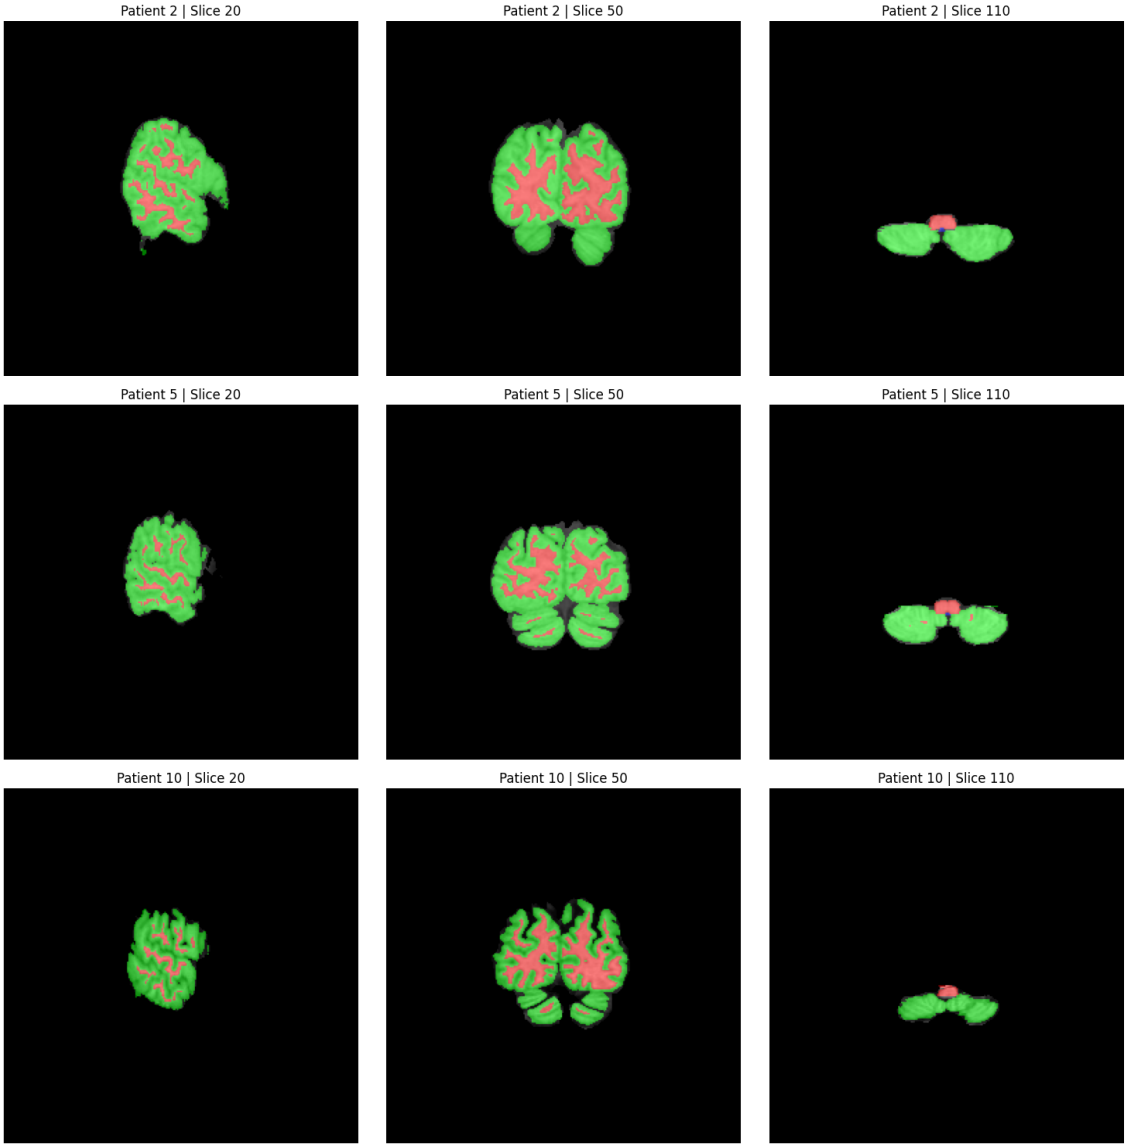
(ب) بیمار ۲



(ج) بیمار ۱۰

شکل ۳: تصاویر مغز بیمارها

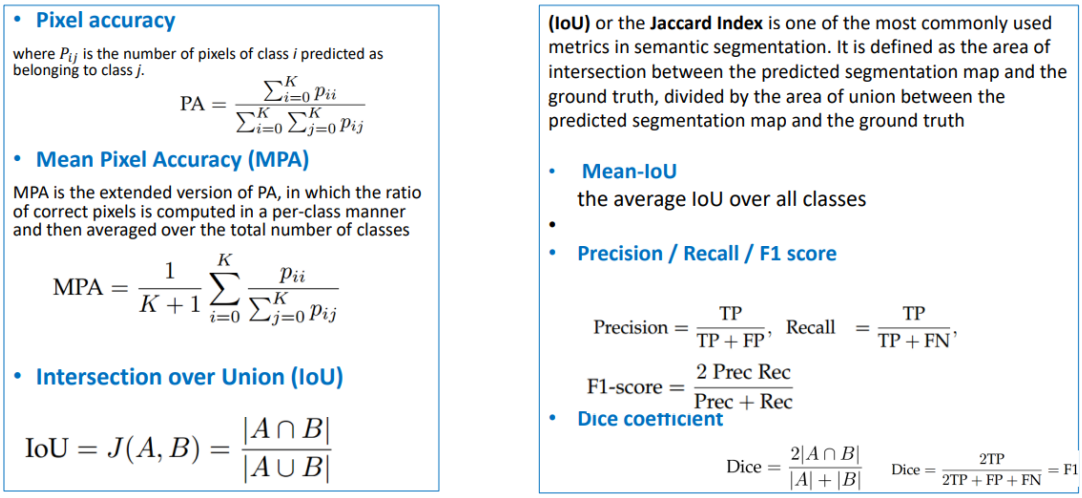
۱ سوال یک



شکل ۴: آموزش بر مبنای patch

جدول ۱ : تعریف متریک ها

Metric	Formula
Dice Coefficient	$\frac{2TP}{2TP + FP + FN + \varepsilon}$
Jaccard Index (IoU)	$\frac{TP}{TP + FP + FN + \varepsilon}$
Precision	$\frac{TP}{TP + FP + \varepsilon}$
Recall	$\frac{TP}{TP + FN + \varepsilon}$



شکل ۵: تعریف متریک ها

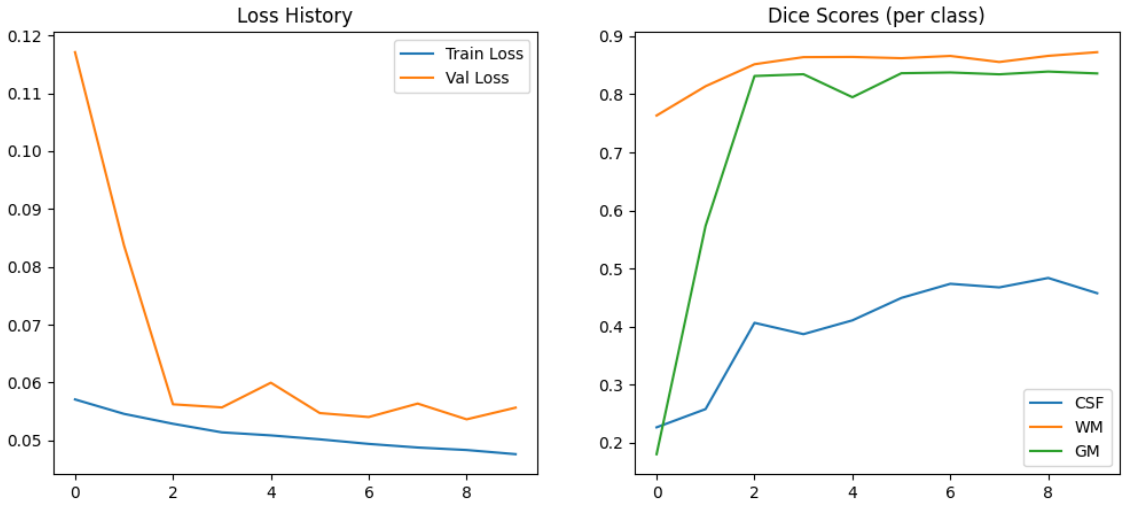
- Dice : زمانی که درست تشخیص دادن و غلط تشخیص ندادن هر دو مهم است، اما درست تشخیص دادن مهم تر است. برای زمانی که دیتاست ما نامتوازن است مناسب است و نشان می دهد که چقدر از ناحیه ای که شبکه تشخیص داده با ناحیه واقعی یکی است. به این علت که تشخیص های غلط در مخرج قرار دارند مدل باید میزان اشتباهش در تشخیص غلط کمینه شود.
- Jacord : نسبت اشتراک به اجتماع دو ناحیه رو می گوید. میزان تشخیص درست به کل تشخیص ها.
- Precision : نشان می‌دهد پیکسل هایی که شبکه به عنوان یک کلاس تشخیص داده، چند درصد درست بوده است.

- Recall : شبکه چه مقدار از ناحیه‌ی واقعی را پیدا کرده است

۱–۴ آموزش مدل

نمودار خطا در شکل ۶ آمده است.

همچنین نتایج آخرین ایپاک هم در جدول ۲ آمده است.



شکل ۶: نمودار dice و loss در ایپاک ها

جدول ۲: خروجی آخرین ایپاک مدل

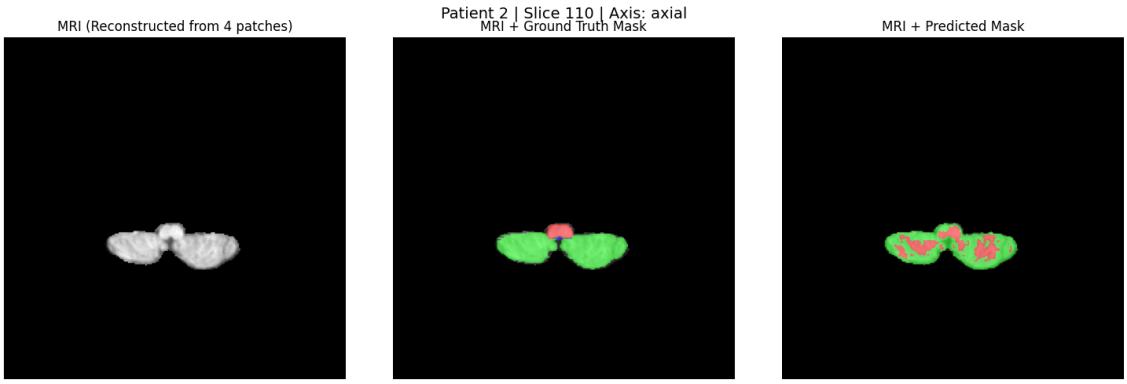
Class	Dice	IoU (Jaccard)	Precision	Recall
BG	۹۹۷۲.۰	۹۹۴۴.۰	۹۹۸۵.۰	۹۹۵۹.۰
CSF	۴۵۷۳.۰	۲۹۶۵.۰	۵۹۷۱.۰	۳۷۰۶.۰
WM	۸۷۲۴.۰	۷۷۳۷.۰	۸۳۹۵.۰	۹۰۸۰.۰
GM	۸۳۵۸.۰	۷۱۷۹.۰	۸۶۲۳.۰	۸۱۰۹.۰

دلیل اینکه کلاس CSF به خوبی تشخیص داده نمی شود این است که مقدار این کلاس نسبت به سه کلاس دیگر به شدت کم است و مدل روی کلاس های دیگر بایاس می شود. برای حل مشکل باید از روش های افزایش دیتا که در تمرین قبلی آمده بود استفاده کرد.

۱–۵ مصور سازی نتایج

خروجی مدل در کنار عکس و ماسک اصلی در شکل ۷ آمده است.

همانطور که مشخص است تصویر ایجاد شده با دقت خوبی در کلاس wm توانسته است مدل اصلی را بازیابی کند اما این اتفاق در کلاس CSF رخ نداده است. کلاس قرمز هم هر چند محدوده اصلی را با دقت خوبی پیش بینی کرده، اما جاهای دیگر را نیز به اشتباه جزو کلاس شناسایی کرده است.



شکل ۷: خروجی مدل در کنار عکس های اصلی

۲ سوال دو

کد مربوط به این سوال در فایل q۲.ipynb قرار دارد.

۲–۱ سوالات نظری

:۱

در nms نکته ای که وجود دارد این است که تمام پرورپزال هایی که از یک آسنانه ای IoU بیشتری نسبت به پروپزالی که امتیاز بیشتری نسبت به آنها دارد داشته باشند به علت جلوگیری از اضافی بودن پروپزال ها و تکرار بیهوده به طور کامل حذف می شوند. این کار باعث می شود که در مکان های شلوغ که اشیاء نزدیک به هم هستند. بعضی پروپزال های درست نیز حذف شوند. soft-nms این پروپزال ها را حذف نمیکند صرفا امتیاز آن ها را کمتر میکند تا اگر واقعا درست بودند بتوان آن ها را شناسایی کرد و دقت مدل افزایش یابد.

:۲

استفاده از mobilNet بجای VGG۱۶ به دلیل اینکه مدل سبک تر و دارای پارامتر های کمتری است باعث می شود که فرآیند آموزش بسیار سریع تر شده و همچنین مصرف حافظه و منابع و حجم مدل کاهش یابد که باعث می شود مدل در فعالیت های real-time عملکرد سریع تری پیدا کند. همچنین این مدل از Convolution Separable Depthwise بجای convolution عادی استفاده می کند که بسیار محاسبات را کاهش می دهد. در عوض این مدل دقت کمتری مخصوصا در شناسایی اشیاء کوچک نسبت به VGG۱۶ خواهد داشت زیرا پارامتر های آن کمتر است و ویژگی ها و مدل هایی که دست میکند ضعیف تر خواهد بود.

:۳

در pooling Roi عادی نکته ای که وجود دارد این است که این روش تنها به داخل باکس ارائه شده نگاه می کند در حالیکه در Pooling RoI context-aware محیط اطراف باکس هم برسی می شود که این در بعضی اشیاء که شبیه هم هستند باعث می شود شناسایی راحت تر شود و تمییز بین آن ها با توجه باه اطلاعات اطراف شی راحت تر صورت بگیرد

۲–۲ مجموعه داده

در این بخش دیتابیس در گوگل درایو به صورت شورت کات استفاده شد. در کگل نیز از دیتاست گفته شده که قلا شخصی آن را آپلود کرده بود استفاده شده است. علت تغیر اسم آن در کد همین است. دیتاست همان است اما نام آن تفات کمی داشته است.

در بخش پیش پردازش داده ها متا دیتای داده ها بر اساس آموزش یا ارزیابی بودنشان در دوفایل جیسون ذخیره شده می شوند که بعدا دیتاست طراحی شده به ازای هر عکس متادیتای آن را نگاه کرده و عکس را لود می کند . همچنین ۴ کلاس وسیله نقلیه در دیتاست تبدیل به یک کلاس وسیله نقلیه شدند و کلاس های با تایپ care don’t حذف شدند. تعداد داده ها قبل پیش پردازش برابر ۱۴۳۸۸ بوده و بعدا از آن تعداد آن برابر ۱۳۹۳۸ عدد شد.

در شکل ۸ باکس بندی داده ها به صورت نمونه نشان داده شده است.



شکل ۸: نمونه باکس بندی داده ها

۲–۳ آپیاده سازی مدل

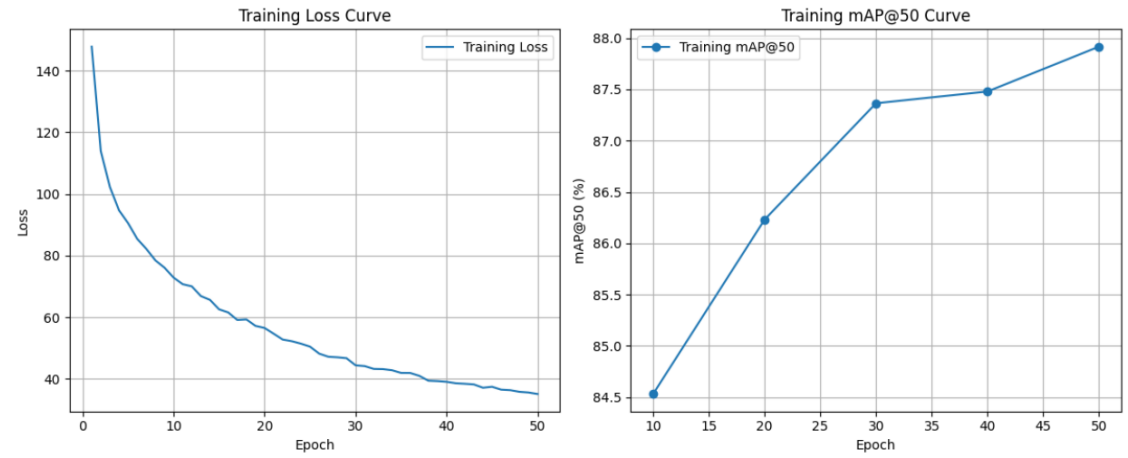
در این بخش پیاده سازی مدل انجام شده است. پیاده سازی بخش soft-nms به دلیل نبود تابع در کتابخانه torch به صورت دستی انجام شده است. همچنین ۲ لایه آخر backbone برای فاین تیونینگ آنفریز شده اند.

تعداد پارامترهای قابل آموزش برابر ۱۸،۳۰۲،۶۱۷ و تعداد کل پارامتر های مدل برابر ۱۸،۸۲۹،۰۱۷ می باشد.

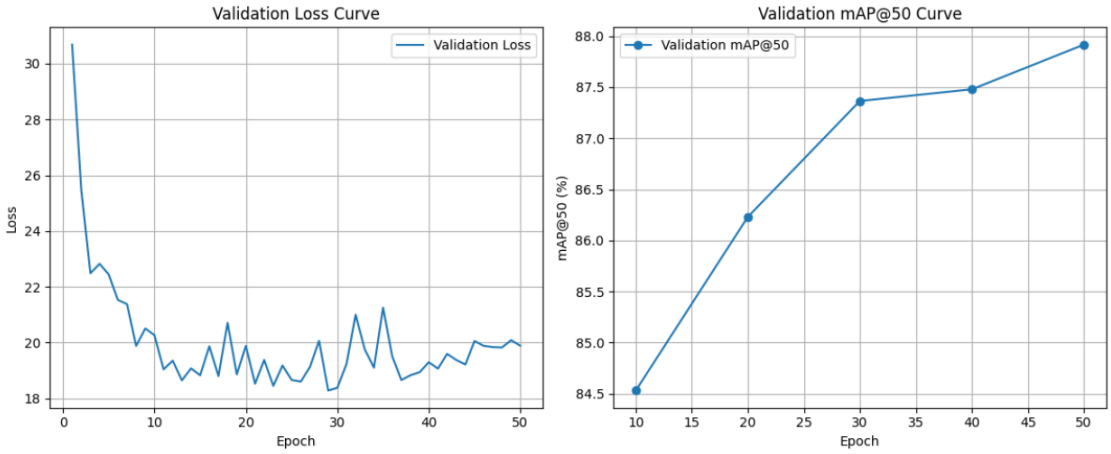
۲–۴ آموزش مدل

در این بخش مدل آموزش میبیند به این صورت که ۴۰ درصد آز داده های آموزش و ۲۰ درصد آز داده های تست را برای آموزش کنار گذاشته و ۱۰ درصد از داده های ارزیابی نیز برای ارزیابی داخلی استفاده شده اند..

در شکل ۹ مقدار خطا و مقدار mAP@۵۰ مدل هنگام آموزش و در شکل ۱۰ هنگام ارزیابی آمده است.



شکل ۹: نمودار تغیرات خطا و دقت در فرآیند آموزش روی داده های آموزش



شکل ۱۰: نمودار تغیرات خطا و دقت در فرآیند ارزیابی

۲–۵ ارزیابی مدل و مصورسازی نتایج

در نهایت مدل روی داده های تست ارزیابی شده و مقدار mAP@۵۰ نهایی برابر ۹۶.۸۷ درصد شده است.

در شکل ۱۱ نیز نمونه ای از خروجی مدل نمایش داده شده است.



شکل ۱۱: نمونه خروجی مدل بعداز آموزش