



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه عصبی

پاسخ تمرین شماره چهارم

سوال اول : علی ممتحن - ۸۱۰۱۰۴۳۲۱

سوال دوم : سید احمد رکنی حسینی - ۸۱۰۱۰۴۳۰۶

فهرست مطالب

فهرست تصاویر ۴

فهرست جداول ۵

۱ سوال یک ۶

۱—۱ آماده سازی داده ۶

۱—۱—۱ . . . . . ۶

۱—۱—۲ . . . . . ۶

۱—۱—۳ . . . . . ۶

۱—۱—۴ . . . . . ۶

۱—۱—۵ . . . . . ۷

۱—۱—۶ . . . . . ۷

۱—۲ مدل های پایه ۸

۱—۲—۱ . . . . . ۸

۱—۲—۲ . . . . . ۹

۱—۳ . . . . . ۹

۱—۴ Decoder Encoder ۱۱

۱—۴—۱ . . . . . ۱۱

۱—۴—۲ . . . . . ۱۱

۱—۴—۳ . . . . . ۱۱

۲ سوال دو ۱۳

۲—۱ آماده سازی داده ۱۳

۲—۱—۱ . . . . . ۱۳

۲—۱—۲ . . . . . ۱۳

۲—۱—۳ . . . . . ۱۷

۲–۱–۴ . . . . . ۱۷
۲–۲ . . . . . ۱۹
۲–۳ مدل پایه ۱۹
۲–۴ . . . . . ۲۱
۲–۴–۱ نمودارهای آموزش مدل - مدل LSTM ۲۱
۲–۴–۲ نمودارهای آموزش مدل - مدل GRU ۲۳
۲–۵ . . . . . ۲۵
۲–۵–۱ . . . . . ۲۵
۲–۵–۲ . . . . . ۲۵
۲–۵–۳ . . . . . ۲۶

فهرست تصاویر

۱ گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی برای مدل BiRNN ۹
۲ گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی نیت برای مدل BiLSTM ۱۰
۳ گزارش تغیرات دقت و خطا در طول آموزش و ارزیابی اسلات برای مدل BiLSTM . . ۱۰
۴ گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی نیت برای مدل Decoder Encoder ۱۱
۵ نمودار تغیرات f۱ در طول آموزش بر روی داده ارزیابی مدل Decoder Encoder . . . ۱۲
۶ نمودار های ACF و PACF قیمت سهام ۱۵
۷ نمودار های ACF و PACF تفاضل مرتبه اول قیمت سهام ۱۶
۸ توزیع مقادیر پنجره های ورودی و خروجی ۱۸
۹ توزیع پنجره های خروجی داده های test train، و validation ۱۹
۱۰ معیارهای ارزیابی مدل پایه در طول فرآیند آموزش ۲۰
۱۱ نمودار پیش بینی قیمت Open با مدل پایه ۲۱
۱۲ معیارهای ارزیابی مدل LSTM در طول فرآیند آموزش ۲۲
۱۳ ساختار مدل LSTM ۲۳
۱۴ معیارهای ارزیابی مدل GRU در طول فرآیند آموزش ۲۴
۱۵ ساختار مدل GRU ۲۵
۱۶ نمودار پیش‌بینی قیمت Close با مدل GRU ۲۶
۱۷ نمودار پیش‌بینی قیمت Close با مدل‌های مختلف ۲۷

فهرست جداول

۱ تعداد واژگان هر قسمت ۶

۲ مقایسه عملکرد مدل‌ها در پیش‌بینی قیمت داده تست ۲۵

۳ گزارش زمان آموزش و تعداد عملیات برای ۵۰ اپک ۲۶

۱ سوال یک

۱–۱ آماده سازی داده

در این بخش پیش پردازش های لازم بر روی داده انجام شده است.

۱–۱–۱

دیتاست مربوطه از کگل لود شده و تعداد دادههای آموزش برابر ۴۲۷۴ و داده های تست برابر ۵۸۶ می باشد. بعد از جدا سازی ۱۰ درصد از دادهها برای ارزیابی تعداد داده های آموزش برابر ۳۸۴۶ و داده های ارزیابی برابر ۴۲۸ شده است.

۱–۱–۲

در این بخش نمونه ای از داده ها نمایش داده شده است.

```
sentence: BOS i want to go between boston and san francisco EOS
slots : O O O O O O B-fromloc.city_name O B-toloc.city_name I-toloc.city_name O
intent: atis_flight
```

۱–۱–۳

۱–۱–۴

تعداد واژگان هربخش در جدول ۱ آمده است.

Number	Type
۸۳۷	vocab word
۱۰۱	vocab slot
۱۷	vocab intent

جدول ۱: تعداد واژگان هر قسمت

همچنین از توکن <UNK> در مرحله آزمون برای کلماتی که در مرحله آموزش دیده نشده اند استفاده می شود. از توکن <PAD> هم برای افزایش طول جمله و یکسان کردن آن در هر بچ استفاده می شود.

۵–۱–۱

ما از پد کردن به اندازه بزرگ ترین جمله هر بچ استفاده می کنیم.

۶–۱–۱

دو نمونه از جملات نمایش داده شده است که همانطور که مشاهده می شود طول آن ها با هم متفاوت است.

```
22
1 - Token IDs: [132, 403, 311, 405, 375, 372, 598, 154,
747, 315, 598, 133, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0]

1 decoded: BOS how do i get from pittsburgh airport
to downtown pittsburgh EOS <PAD> <PAD> <PAD> <PAD>
<PAD> <PAD> <PAD> <PAD> <PAD> <PAD>

2 - Token IDs: [132, 809, 357, 464, 250, 379, 747,
418, 574, 176, 775, 353, 411, 724, 530, 133,
0, 0, 0, 0, 0, 0]

2 decoded: BOS what flights leave cleveland going
to indianapolis on april twenty first in the
morning EOS <PAD> <PAD> <PAD> <PAD> <PAD> <PAD>

first batch 22
==============
26
```

```
1 - Token IDs: [132, 670, 506, 724, 357, 372, 190,
747, 214, 133, 0, 0, 0, 0, 0, 0, 0, 0, 0,
0, 0, 0, 0, 0, 0, 0]

1 decoded: BOS show me the flights from atlanta
to boston EOS <PAD> <PAD> <PAD> <PAD> <PAD>
<PAD> <PAD> <PAD> <PAD> <PAD> <PAD> <PAD>
<PAD> <PAD> <PAD> <PAD>

2 - Token IDs: [132, 829, 574, 724, 287, 356, 466,
642, 368, 189, 58, 604, 187, 595, 22, 604,
809, 777, 566, 332, 427, 786, 574, 722,
356, 133]

2 decoded: BOS yes on the delta flight leaving
san francisco at 225 pm arriving philadelphia
1158 pm what type of equipment is used on that
flight EOS

second batch 26
```

با پد کردن به اندازه بچ میتوانیم در انجام محاسبات صرفه جویی کنیم زیرا ممکن است در کل دیتاست یک جمله بسیار طولانی وجود داشته باشد که اگر پد را به اندازه آن بگیریم تنسور ورودی بسیار بلند خواهد شد اما اگر بچ بچ این پدینگ را عوض کنیم صرفا بچ مربوط به آن بلند خواهد شد. و به طور کلی در محاسبات صرفه جویی خواهد شد.

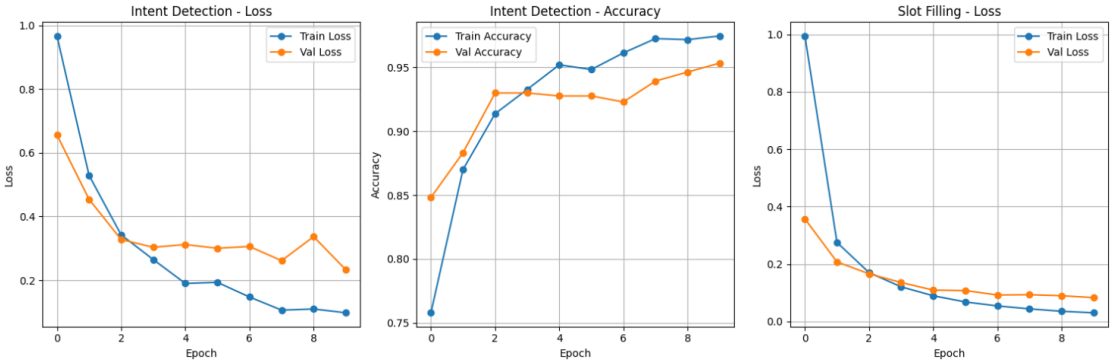
۱–۲ مدل های پایه

۱–۲–۱

کد های پیاده سازی معماری این مدل در فایل q۱.ipynb آمده است.

۲–۲–۱

نمودار های ارزیابی و آموزش برای خطا در طول آموزش هم برای intent و هم برای slot به همراه مقدار دقت برای intent در شکل ۱ نمایش داده شده است.



شکل ۱: گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی برای مدل BiRNN

همچنین دقت در تشخیص نیت بر روی داده تست برابر ۹۵ درصد بدست آورده شده است. مقدار F۱ score نیز بر روی داده تست برابر ۹۳.۰ محاسبه شده است که بیشتر از درخواستی سوال می باشد.

دلیل اینکه از کتابخانه seqeval (کتابخانه مخصوص labeling sequence) بجای sklearn برای محاسبه معیار های خواسته شده استفاده می کنیم این است که کتابخانه sklearn در سطح توکن درستی و دقت را ارزیابی می کند اما کتابخانه seqeval در سطح موجودیت یا entity درستی را برسی می کند برای مثال اگر جمله این باشد

from Boston to New York

آنگاه مدل ما توکن های from و to را برای boston و new درنظر بگیرد کتابخانه sklearn آن را صحیح درنظر میگیرد درحالیکه کتابخانه دیگر سختگیرانه تر عمل کرده و امتیاز کمتری میدهد زیرا باید هردوی new York به عنوان برچسب to درنظر گرفته شوند.

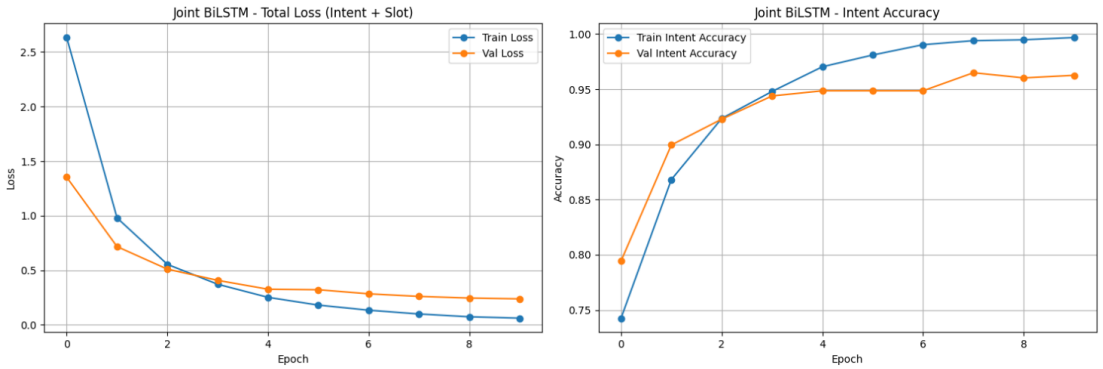
۳–۱

در اینجا چون هردوی نیات و اسلات ها با یک مدل درست می شوند. تابع هزینه برابر مجموع تابع هزینه این دو به گفته خد سوال در نظر گرفته شده است.

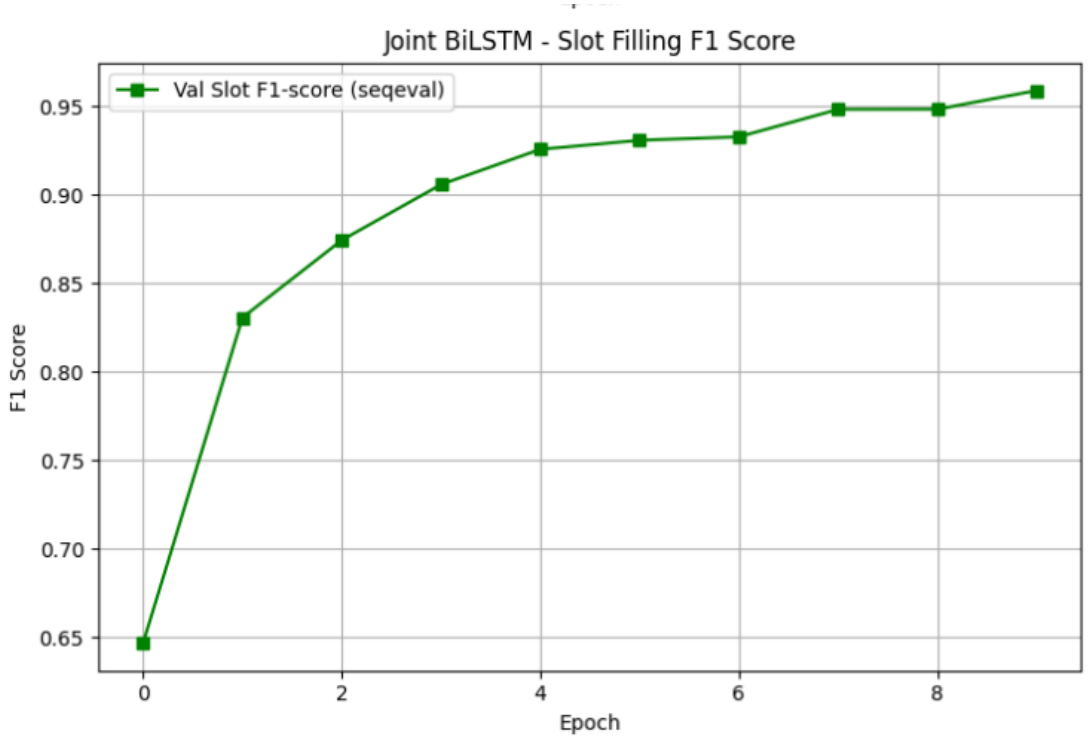
۱ سوال یک

نمودار های ارزیابی و آموزش برای خطا در طول آموزش هم برای intent به همراه مقدار دقت برای intent در شکل ۲ نمایش داده شده است. مقدار خطا در طول آموزش و ارزیابی برای اسلات ها نیز در شکل ۳ نمایش داده شده است.

همچنین مقدار دقت بر تشخیص نیت بر روی داده های تست حدود ۹۸ درصد و مقدار f۱ برای اسلات ها حدود ۹۴.۰ می باشد. که بهتر از مدل قبلی است.



شکل ۲: گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی نیت برای مدل BiLSTM



شکل ۳: گزارش تغیرات دقت و خطا در طول آموزش و ارزیابی اسلات برای مدل BiLSTM

Decoder Encoder ۴–۱

۱–۴–۱

در این سوال قرار است از مدل انکودر دیکودر استفاده کنیم . وجود دیکودر باعث می شود که ارتباط بین دنباله ورودی و خروجی از نظر اندازه مستقیم نباشد که می تواند کاری کند خروجی مدل طول به مراتب متفات تری نسبت به ورودی داشته باشد.

این دوتا توکن را در وازگان اسلات ها اضافه کردیم دلیل نیاز به این توکن ها این است که لازم است مدل دیکودر بتواند اتمام جمله را مشخص کند و با توکن ابتدایی جمله را شروع کند. و برای شروع تولید از این توکن استفاده کند.

۲–۴–۱

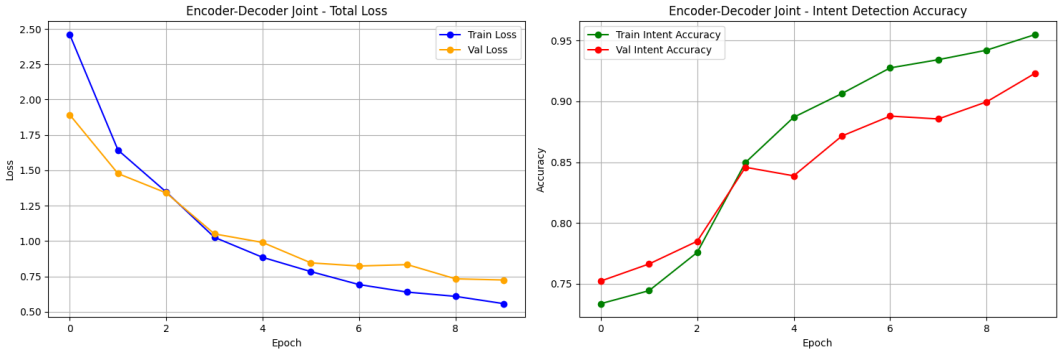
پیاده سازی معماری در فایل انجام شده است.

۳–۴–۱

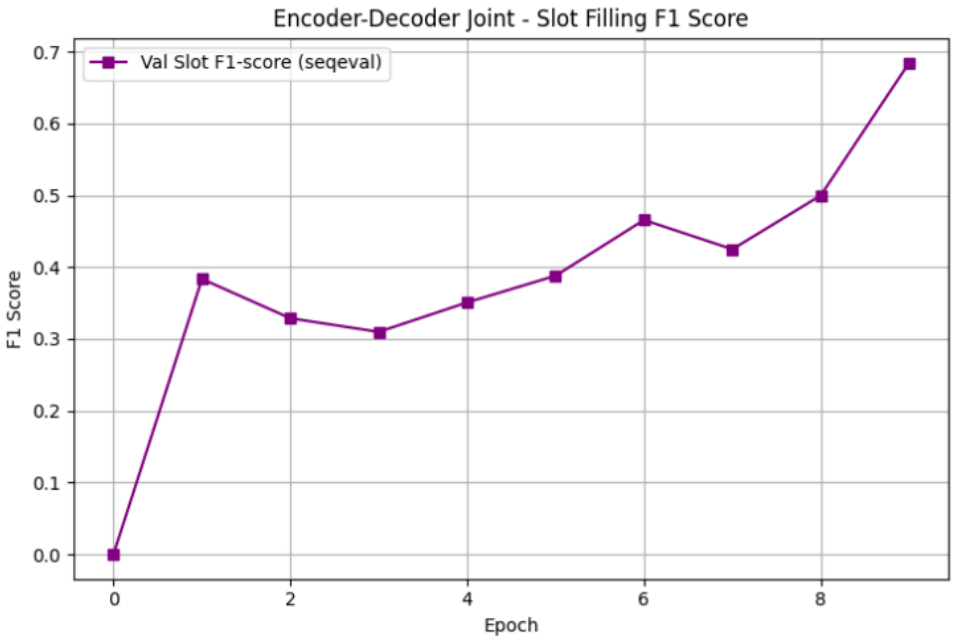
نمودار های خطا و دقت در طول آموزش و ارزیابی برای تشخیص نیت در این مدل در شکل ۴ آمده است.

همچنین نمودار f۱ برای اسلات ها نیز در شکل ۵ آمده است.

مقدار دقت روی تشخیص نیت در این مدل برابر ۹۳ درضد بر روی داده های تست شده است. همچنین مقدار f۱ برای تشخیص اسلات ها بر روی داده های تست حدود ۴۶.۰ شده است.



شکل ۴: گزارش تغیرات دقت و خطا در طول آمزش و ارزیابی نیت برای مدل Decoder Encoder



شکل ۵: نمودار تغیرات f۱ در طول آموزش بر روی داده ارزیابی مدل Decoder Encoder

عملکرد این مدل به این دلیل ضعیف است که ارتباط بین اندازه جمله ورودی و خروجی کمرنگ می شود و انتقال اطلاعات از ورودی به خروجی تنها از یک بردار ۱۲۸ تایی صورت می گیرد در نتیجه پیدا کردن اسلات های درست سخت تر شده و نتیجه آن خوب نمی شود.

ایده ای که برای حل این مشکل گفته شده است این است که بجای اینکه صرفا استیت پنهان انهایی انکودر و cell-state نهایی آن را به مدل دیکودر بدهیم در هر تایم در دیکودر استیت پنهان و cell-state متناظر انکودر در آن زمان را به عنوان ورودی بدهیم اینکار باعث می شود تا ارتباط بین اندازه ورودی به خروجی به طور مستقیم برقرار شده و مدل نتایج بهتری بدهد.

۲ سوال دو

۲–۱ آماده سازی داده

۲–۱–۱

دلیل استفاده از normalization این است که تاثیر تغییر سال ها را بر آموش مدل تا جای ممکن کم کنیم، هر چقدر عددی بزرگتر باشد تاثیر بیشتری بر تغییر پارامترها دارد و ما با بردن بازه آن ها بین ۰ تا ۱ باعث می شویم که این اثر خیلی کمتر از وقتی شود که اعداد بین ۲۰۰۰ تا ۲۰۲۰ هستند.

۲–۱–۲

ابتدا بهتر است معانی هر یک از عبارات را توضیح دهیم، انگاه به بررسی هر کدام از آن ها در سری زمانی داده شده بپردازیم :

- PACF : این پارامتر نشان می دهد که مقدار سری در lag روز پیش چقدر به صورت مستقیم در مقدار الان آن پارامتر تاثیر دارد. برای مثال قیمت ۴۰ روز پیش یک سهام چقدر به صورت مستقیم در قیمت امروز آن اثر دارد. این اثر با correlation محاسبه می شود.
- ACF : این پارامتر هم مانند پارامتر PACF است با این تفاوت که در آن ما تاثیر مستقیم را نمی سنجیم، بلکه تاثیر از طریق قیمت روز های وسط بین آن ها را هم می سنجیم. برای مثال قیمت ۴۰ روز پیش با تاثیر گذاشتن بر قیمت ۳۹ روز پیش و ۳۸ روز پیش و ... تاثیری در قیمت امروز داشته است. این تاثیر با پارامتر ACF نشان داده می شود.
- تفاضل گیری : به جای دیدن اثر پارامتر ها برخود قیمت ها، اثر آن ها را بر تغییر قیمت ها ببینیم. تفاضل مرتبه یک برابر $x' = x_t - x_{t-1}$ هست. تفاضل مرتبه دو همین موضوع هست برای x'.
- stationarizing : در صورتی که یک سری در بازه های مختلف دارای میانگین و واریانس تقریبا ثابت باشد آن سری ایستا می باشد.

باتوجه به توضیحات داده شده متوجه می شویم که برای محاسبه پنچره ورودی باید به نمودار PACF نگاه کنیم تا متوجه شویم تا چند عدد قبلی در سری زمانی بر عدد الان تاثیر جدی دارد.

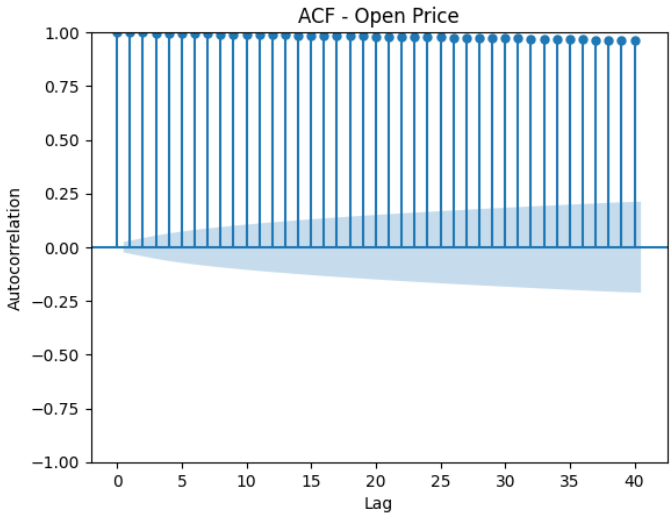
۲ سوال دو

برای محسابه افق پیش بینی هم باید به نمودار ACF نگاه کرد تا متوجه شد که مجموعا تاثیرات تا چند نمونه بعد از خودشان propagate می شوند.

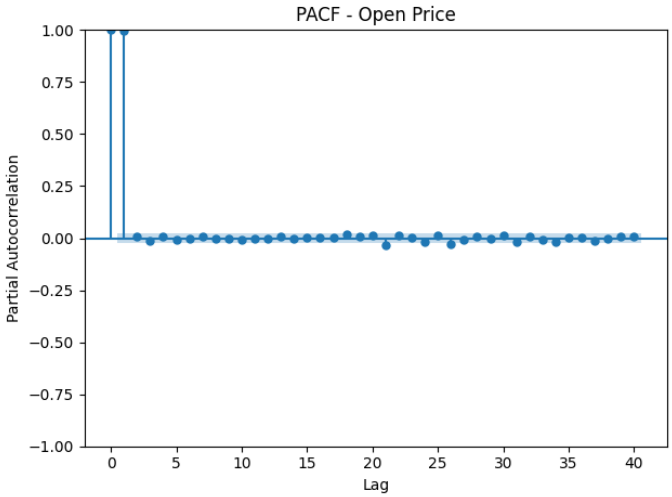
ابتدا به سراغ نمودارهای خود قیمت می رویم.

همانطور که در شکل ۶ نشان داده شده است در این حالت ACF تا لگ های بسیار بالا تاثیر عمیقی دارد. دلیل این اتفاق چه می تواند باشد ؟ دلیل آن این است که اعداد قیمت ها بسیار زیاد هستند و تاثیرات پیش بینی در اعداد بزرگ گم می شود. این اتفاق سبب می شود که اگر یک مبلغ به جای 100000 دلار، 110000 دلار پیش بینی شود خیلی اثر آن مشخص نباشد.

به همین خاطر ما به سراغ نمودار تفاضل مرتبه ۱ می رویم تا بتوانیم دقت بیشتری داشته باشیم. با دیدن تغییرات قیمت ها به جای خود قیمت ها نمودارهای ACF و PACF زودتر به سمت صفر می روند و بهتر می توان متغیرهای اثر گذار را شناسایی کرد. این نمودار در شکل ۷ نشان داده شده است.

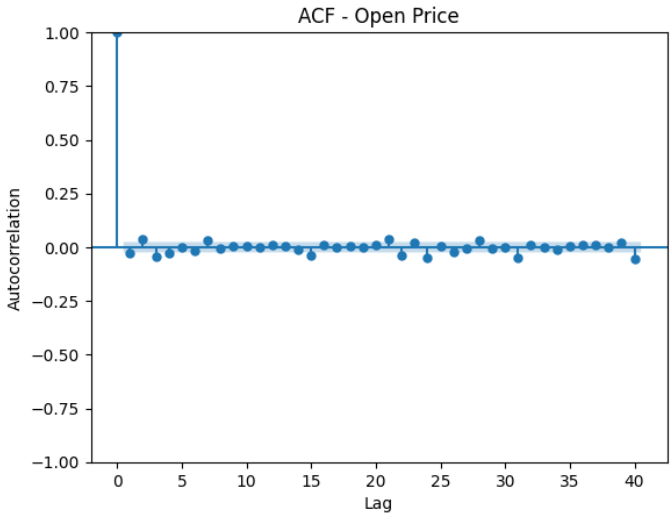


ACF (آ)

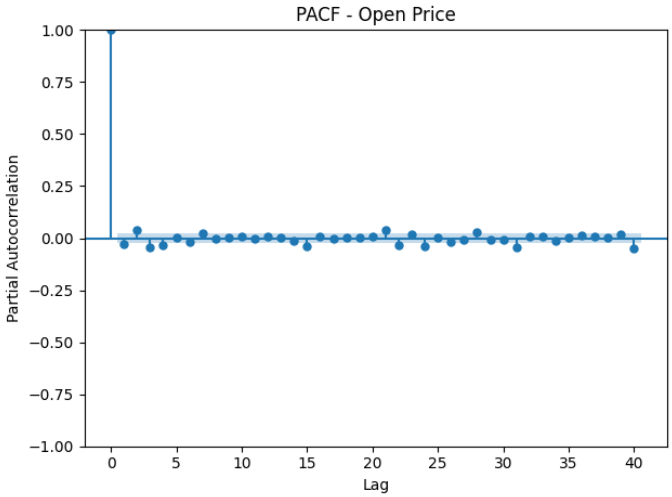


PACF (ب)

شکل ۶: نمودار های ACF و PACF قیمت سهام



ACF (آ)



PACF (ب)

شکل ۷: نمودار های ACF و PACF تفاضل مرتبه اول قیمت سهام

با توجه به نمودار های شکل ۷ در می‌یابیم که تنها مقدار ۱ برای پنجره خروجی معنا دار است، اما برای پنجره ورودی، از آنجا که همه مقادیر PACF به شدت کم هستند، می بایست ابعاد پنجره ورودی بزرگ و در حدود ۲۰ انتخاب شود.

در نهایت با انجام آزمون ADF که تستی بر مبنای hypothesis testing می باشد مشخص شد که p-value در تفاضل مرتبه ۱ به اندازه کافی کوچک می باشد، بنابر این سری در تفاضل مرتبه ۱ ایستا می باشد.

۳–۱–۲

پروسه ergodic برای چند سری زمانی تعریف می شود. در صورتی که چند سری زمانی در بازه زمانی طولانی مدت میانگین و واریانس نسبتا یکسانی داشته باشند و با میانگین و واریانس جامعه برابر باشد. به این سری های زمانی ergodic گفته می شود.

ما از تعریف بالا می توانیم یک تعریف تقریبی هم برای ergodic بودن یک سری زمانی پیدا کنیم و بگوییم اگر میانگین و واریانس یک سری زمانی در بازه نسبتا طولانی برابر میانگین و واریانس کل جامعه باشد به آن سری زمانی ergodic گفته می شود.

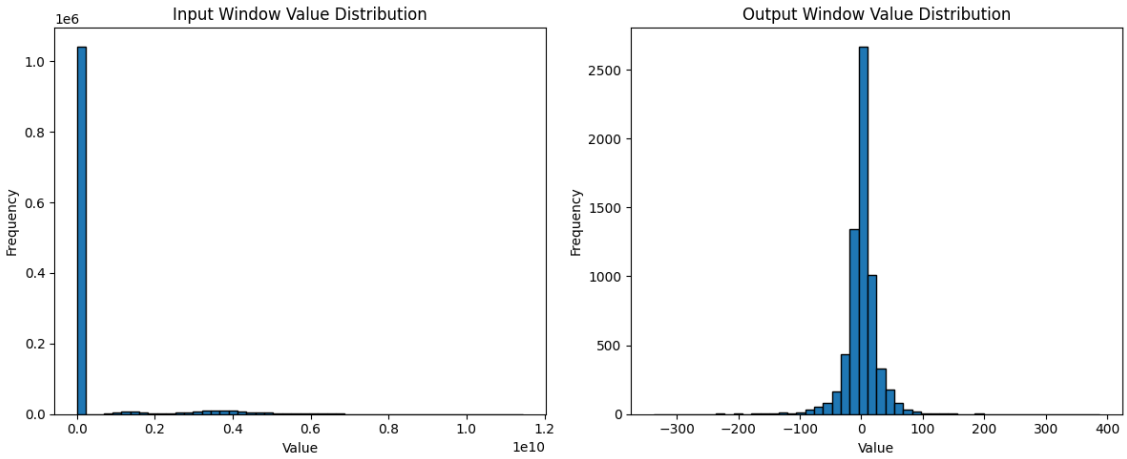
در مدل های DL و ML هم توزیع بودن ورودی ها بسیار به یادگیری بهتر مدل کمک می کند، بنابراین ایستا بودن، که سبب می شود هر بخش سری که به عنوان ورودی به مدل داده می شود دارای واریانس و میانگین یکسان باشد، تقریبا لازم است.

اما اینکه این میانگین و واریانس با میانگین و واریانس خود جامعه یکی باشد (معنای ergodic بودن در یک سری) حتما لازم نیست، اما دارای ارزش مثبت است.

باتوجه به بررسی انجام شده در کد قیمت های Open درای ویژگی ergodic نیستند.

۴–۱–۲

از آنجایی که در قسمت های پیشین اندازه مناسب پنجره خروجی و ورودی را به دست آوردیم، و این موارد را در تفاضل مرتبه اول به دست آوردیم، اندازه پنجره ها همان می مانند. هیستوگرام مقادیر این پنجره ها در شکل ۸ آمده است. واضح است به علت وجود داده های سینوسی و کسینوسی و همچنین مقدار نرمال سال ها در پنجره ورودی، این هیستوگرام دارای تعداد زیادی عدد بین ۰ تا ۱ می باشد.

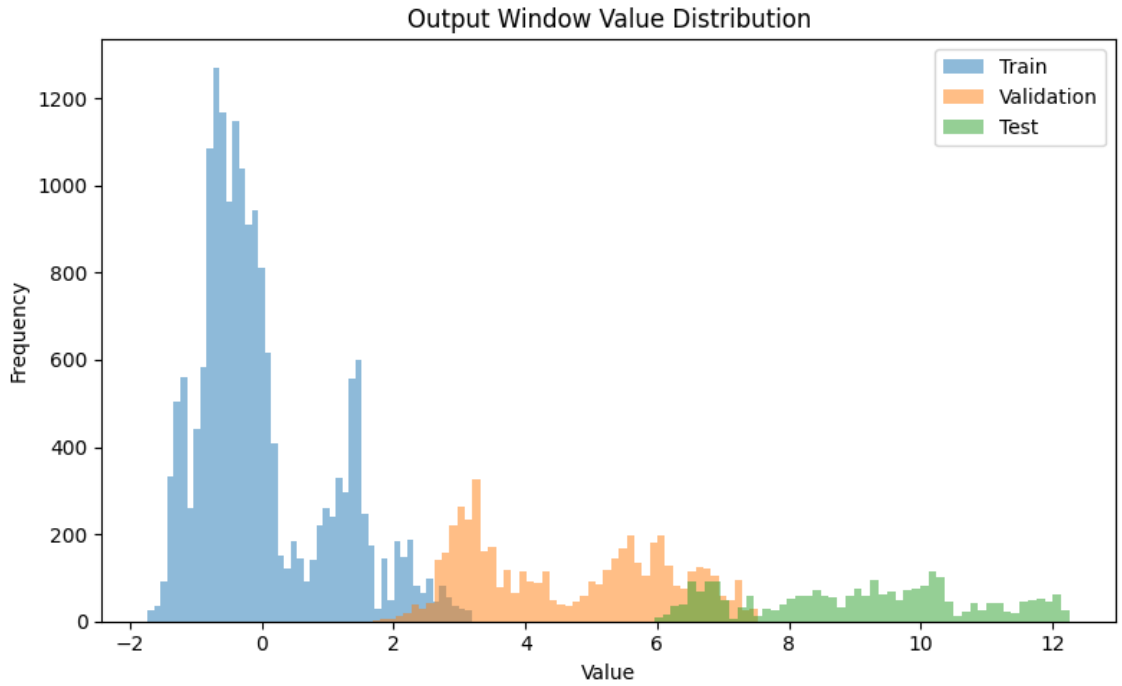


شکل ۸: توزیع مقادیر پنجره های ورودی و خروجی

Data Leakage به معنی این است که ما اطلاعاتی از داده های تست و ولیدیشن را وارد داده ترین کنیم. در صورتی که این کار را انجام دهیم، انگار واقعا داده های تست و ولیدیشن جدا از داده های ترین نیستند. پس مدل هنگامی که دارد روی داده های ترین آموزش می بیند، اطلاعاتی از داده های تست و ولیدیشن هم می فهمد. پس دیگر با داده های تست و ولیدیشن نمی شود یک ارزیابی واقعی از مدل داشت.

با توجه به توضیحات بالا ما نباید Data leakage داشته باشیم. پس هنگامی که داریم داده ها را نرمال سازی می کنیم، باید فقط از μ و σ ترین برای نرمال سازی همه داده ها استفاده کنیم. چرا نباید از μ و σ کل دیتاها استفاده کنیم ؟ دلیل آن این است که کل جامعه شامل داده های تست و ولیدیشن هم هستند و اگر از آن ها استفاده کنیم Data leakage خواهیم داشت.

پس از نرمال سازی داده ها را به سه بخش ،test train و validation تقسیم کردیم. هر بخش را به پنجره های ورودی و خروجی تقسیم کردیم و هیستوگرام آن‌ها را در شکل ۹ نشان داده ایم.



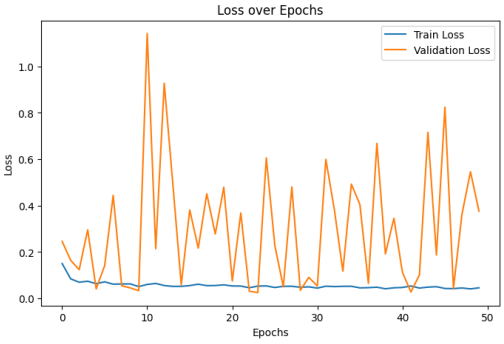
شکل ۹: توزیع پنجره های خروجی داده های train، test و validation

۲–۲

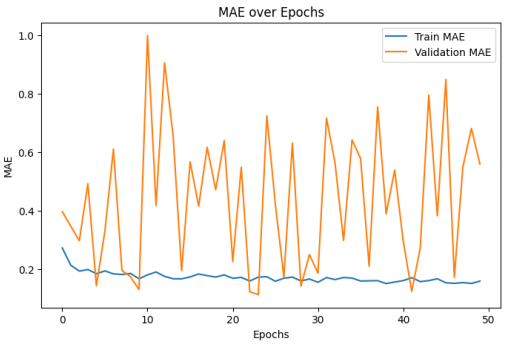
در پنجره ورودی مدل ما از هر چهار ویژگی برای پیش بینی قیمت ها استفاده کرده ایم.

۲–۳ مدل پایه

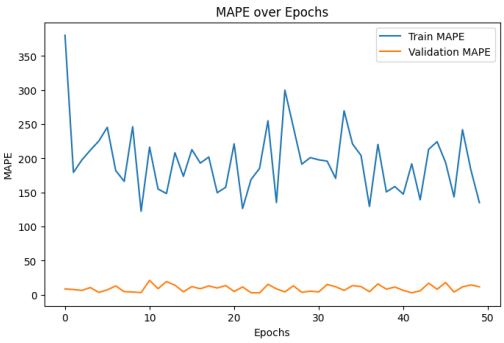
در شکل ۱۰ نمودارهای مختلف معیارهای ارزیابی برای مدل پایه در طول آموزش نشان داده شده است.



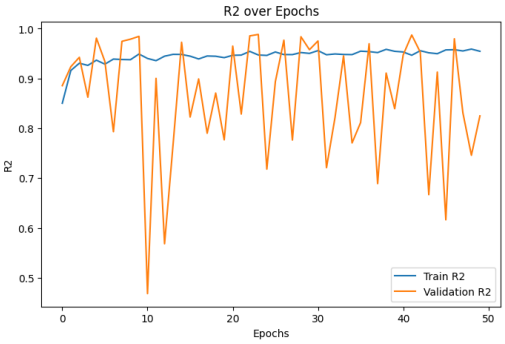
(آ) تابع زیان در طول اپک‌ها



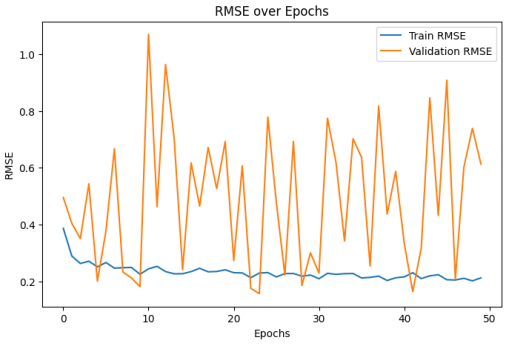
(ب) میانگین خطای مطلق (MAE) در طول اپک‌ها



(ج) میانگین درصد خطای مطلق (MAPE) در طول اپک‌ها



(د) ضریب تعیین (R۲) در طول اپک‌ها

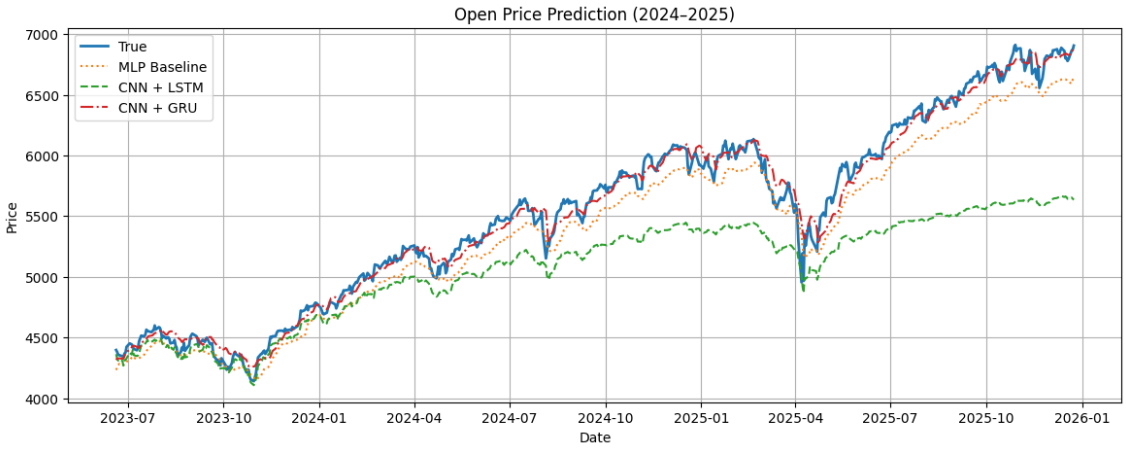


(ه) جذر میانگین مربعات خطا (RMSE) در طول اپک‌ها

شکل ۱۰: معیارهای ارزیابی مدل پایه در طول فرآیند آموزش

همانطور که مشخص است در مدل پایه آموزش اصلا پایدار نیست و نمودارها دارای اعوجاج بسیار زیادی هستند.

نتیجه خروجی همه مدل ها روی داده های تست در شکل ۱۱ آمده است.



شکل ۱۱: نمودار پیش بینی قیمت Open با مدل پایه

تعداد پارامترهای مدل هم برابر با $32,068$ می باشد.

۴–۲

۱–۴–۲ نمودارهای آموزش مدل - مدل LSTM

در شکل ۱۲ نمودارهای مختلف معیارهای ارزیابی برای مدل LSTM در طول آموزش نشان داده شده است.

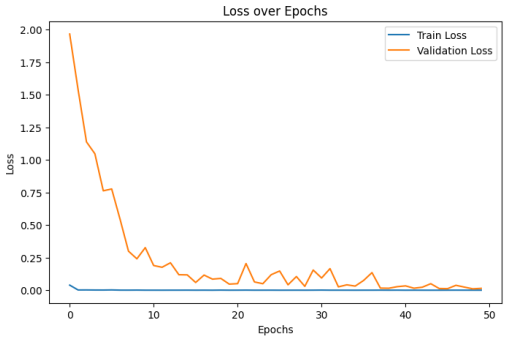
لایه‌های کانولوشنی یک بعدی بر روی بعد زمانی اعمال می‌شوند و با کرنل‌هایی با طول محدود، الگوهای محلی و وابستگی‌های کوتاه‌مدت زمانی را از کل پنجره ورودی استخراج می‌کنند. هر فیلتر کانولوشنی در واقع زیرتوالی‌هایی به طول کرنل را مشاهده کرده و با انجام عمل کانولوشن، feature هاییmap شامل اطلاعات روندها و نوسانات کوتاه‌مدت تولید می‌کند.

خروجی لایه کانولوشن به‌عنوان توالی ویژگی‌ها به لایه‌های LSTM داده می‌شود. لایه LSTM با بهره‌گیری از حافظه داخلی، وابستگی‌های بلندمدت میان map feature استخراج‌شده را مدل کرده و ساختار زمانی کلی سری را یاد می‌گیرد.

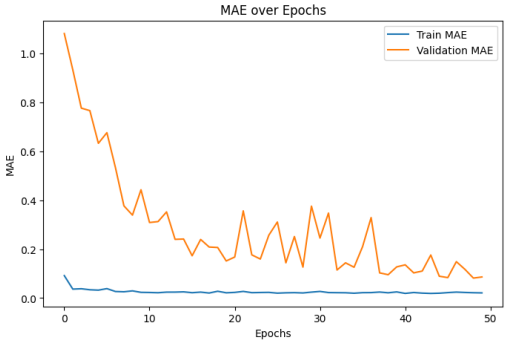
همچنین از آخرین خروجی LSTM برای این اتصال به لایه های fc استفاده می شود.

این خروجی خلاصه‌ای فشرده از کل توالی ورودی تا آخرین گام زمانی را در بر دارد. استفاده از تمام hidden feature معمولاً باعث افزایش تعداد پارامترها و خطر overfitting می‌شود، در حالی که آخرین

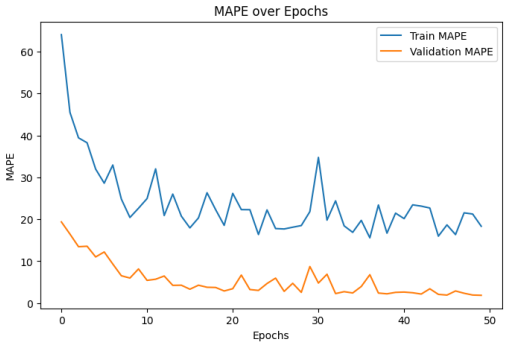
خروجی LSTM چکیده مناسبی از اطلاعات کل توالی را ارائه می‌دهد که برای پیش‌بینی نهایی کافی است.



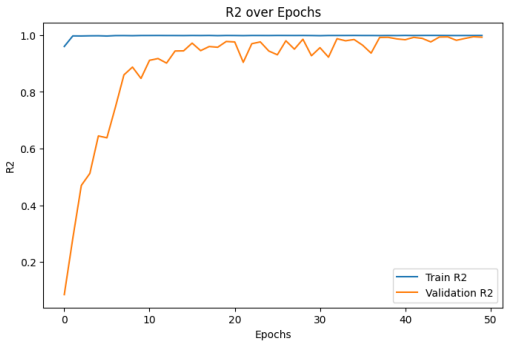
(آ) تابع زیان در طول اپک‌ها



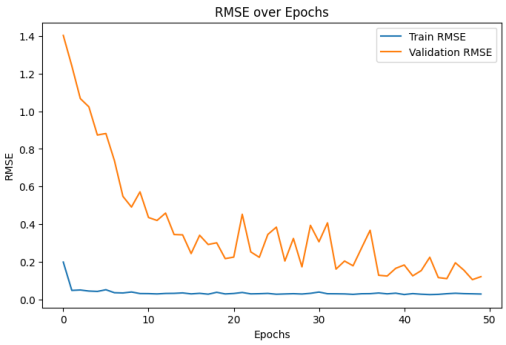
(ب) میانگین خطای مطلق (MAE) در طول اپک‌ها



(ج) میانگین درصد خطای مطلق (MAPE) در طول اپک‌ها



(د) ضریب تعیین (R^2) در طول اپک‌ها



(ه) جذر میانگین مربعات خطا (RMSE) در طول اپک‌ها

شکل ۱۲: معیارهای ارزیابی مدل LSTM در طول فرآیند آموزش

ساختار این مدل و تعداد پارامترهای آن در شکل ۱۳ آمده است.

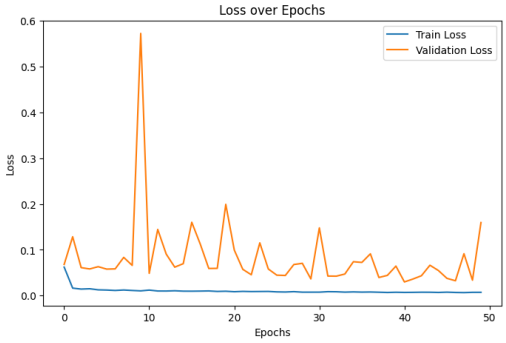
```
CNN + LSTM Summary
==========================================================================================
Layer (type:depth-idx)                   Output Shape              Param #
==========================================================================================
CNN_LSTM                                 [32, 4]                   --
├─Conv1d: 1-1                            [32, 64, 18]              1,792
├─LSTM: 1-2                              [32, 18, 512]             1,183,744
├─Linear: 1-3                            [32, 256]                 131,328
├─ReLU: 1-4                              [32, 256]                 --
├─Linear: 1-5                            [32, 4]                   1,028
==========================================================================================
Total params: 1,317,892
Trainable params: 1,317,892
Non-trainable params: 0
Total mult-adds (Units.MEGABYTES): 687.10
==========================================================================================
Input size (MB): 0.02
Forward/backward pass size (MB): 2.72
Params size (MB): 5.27
Estimated Total Size (MB): 8.02
==========================================================================================
```

شکل ۱۳: ساختار مدل LSTM

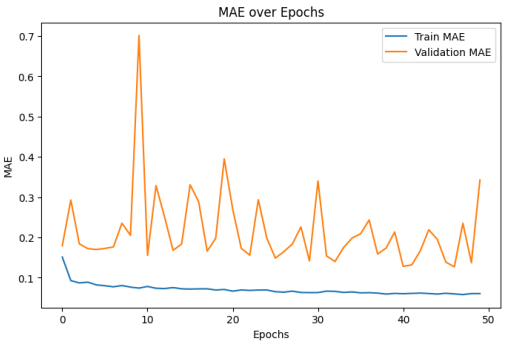
همچنین در انتها این مدل loss کمتری نسبت به مدل پایه داشت.

۲–۴–۲ نمودارهای آموزش مدل - مدل GRU

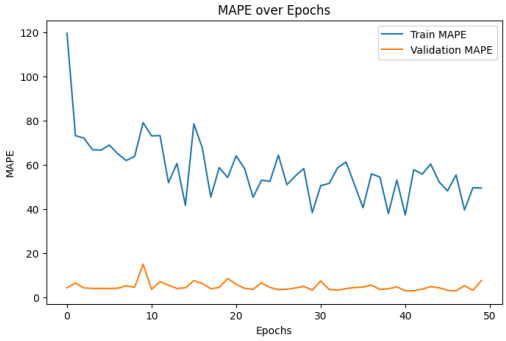
در شکل ۱۴ نمودارهای مختلف معیارهای ارزیابی برای مدل GRU در طول آموزش نشان داده شده است.



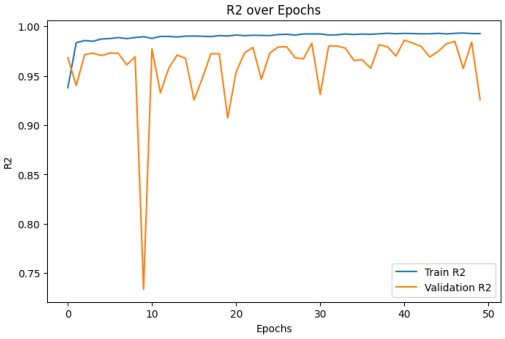
(آ) تابع زیان در طول اپک‌ها



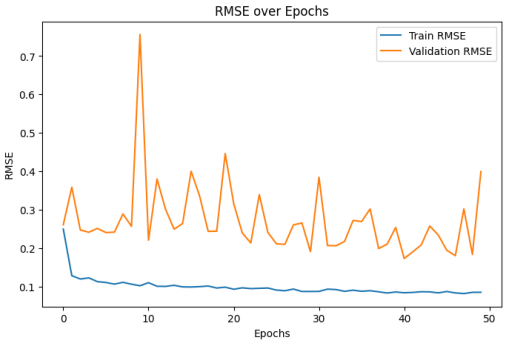
(ب) میانگین خطای مطلق (MAE) در طول اپک‌ها



(ج) میانگین درصد خطای مطلق (MAPE) در طول اپک‌ها



(د) ضریب تعیین (R۲) در طول اپک‌ها



(ه) جذر میانگین مربعات خطا (RMSE) در طول اپک‌ها

شکل ۱۴: معیارهای ارزیابی مدل GRU در طول فرآیند آموزش

ساختار و تعداد پارامترهای این مدل در شکل ۱۵ آمده است.

در این مسئله، استفاده از hidden featureهای لایهٔ آخر GRU مناسب‌تر از استفاده از خروجی نهایی به‌تنهایی است، زیرا چکیده بهتری از اطلاعات در آنها ذخیره می شود و اطلاعات وابستگی‌های بلندمدت را

```
CNN + GRU Summary
==========================================================================================
Layer (type:depth-idx)                   Output Shape              Param #
==========================================================================================
CNN_GRU                                  [32, 4]                   --
├─Conv1d: 1-1                            [32, 64, 20]              4,096
├─GRU: 1-2                               [32, 20, 512]             5,615,616
├─Linear: 1-3                            [32, 256]                 147,712
├─ReLU: 1-4                              [32, 256]                 --
├─Dropout: 1-5                           [32, 256]                 --
├─Linear: 1-6                            [32, 4]                   1,028
==========================================================================================
Total params: 5,768,452
Trainable params: 5,768,452
Non-trainable params: 0
Total mult-adds (Units.GIGABYTES): 3.60
==========================================================================================
Input size (MB): 0.02
Forward/backward pass size (MB): 3.02
Params size (MB): 23.07
Estimated Total Size (MB): 26.11
==========================================================================================
```

شکل ۱۵: ساختار مدل GRU

به‌صورت پایدارتر منتقل می‌کند. بنابراین، بهره‌گیری از feature hidden در لایهٔ آخر موجب بهبود کیفیت پیش بینی می‌شود.

۵–۲

۱–۵–۲

جدول ۲: مقایسه عملکرد مدل‌ها در پیش‌بینی قیمت داده تست

Model	R^2	MAE	RMSE	MAPE	Params Number
MLP Baseline	0.9695	108.85	131.42	1.94	32,068
CNN + LSTM	0.4410	439.22	563.00	7.28	1,317,892
CNN + GRU	0.9854	68.23	91.10	1.26	5,768,452

۲–۵–۲

آموزش مدل روی kaggle انجام شد به وسیله 2 × T4 GPU

زمان‌ها و تعداد عملیات‌های آموزش در جدول ۳ آمده است.

جدول ۳: گزارش زمان آموزش و تعداد عملیات برای ۵۰ اپک

مدل	زمان آموزش	تقریب FLOPs (دو برابر تعداد پارامترها)
MLP Baseline	۰ دقیقه و ۱۸ ثانیه	۶۴،۱۳۶
CNN + LSTM	۰ دقیقه و ۲۹ ثانیه	۲،۶۳۵،۷۸۴
CNN + GRU	۱ دقیقه و ۳۷ ثانیه	۱۱،۵۳۶،۹۰۴

۳–۵–۲

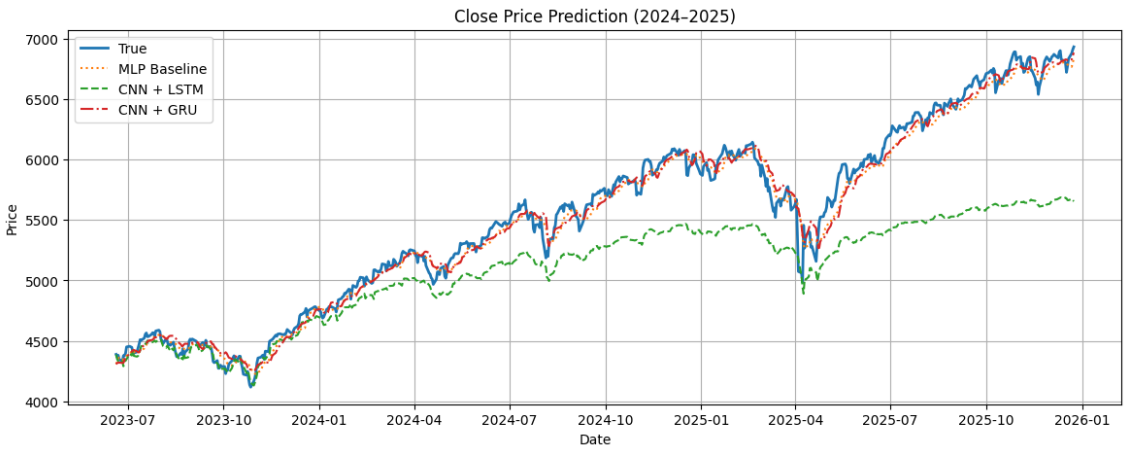
نمودار قیمت Close در شکل ۱۶ آمده است.

همانطور که در شکل مشخص است LSTM در ابتدا به خوبی توانسته است پیچیدگی های منحنی را یادبگیرد، اما پس از مدتی فاصله به شدت زیادی با نمودار اصلی پیدا می کند.

مدل GRU بهتر از LSTM عمل کرده است و توانسته است و توانسته روند کلی نمودار را یادبگیرد.

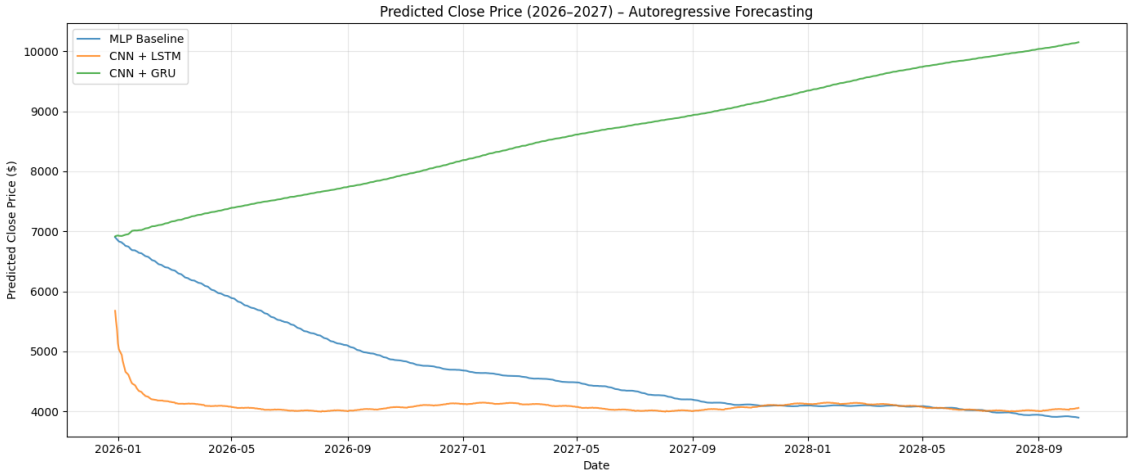
اما مدل Baseline تقریبا به خوبی مدل GRU روند کلی را یاد گرفته است اما با تعداد پارامتر خیلی کمتر.

اما در کل همانطور که مشخص است، مدل GRU در فهم روند کلی نمودار و مدل LSTM در فهم پیچیدگی های نمودار بهترین عمل کرد را داشتند.



شکل ۱۶: نمودار پیش‌بینی قیمت Close با مدل GRU

اما علت اینکه چرا نمی توان از با استفاده از این مدل ها آینده خیلی دور را پیش بینی کرد در نمودار



شکل ۱۷ : نمودار پیش‌بینی قیمت Close با مدل‌های مختلف

PACF و ACF که در ابتدا رسم کردیم نهفته است،

ذات دیتای مالی خیلی خبری از دیتای آینده خود نمی دهد، در نتیجه مدل های مبتنی بر حافظه هرچقدر هم که خوب باشند نمی توانند پیش بینی خوبی را ارائه دهند.

با دیدن نمودار قبل می توان اطلاعاتی هم در رابطه با پیش بینی آن ها از قیمت سال بعد به دست آورد.

همانطور که مشخص است مدل LSTM وزن زیادی به داده های خیلی دور می دهد، پس احتمالا روند کلی آن برای سال آینده خیلی تغییر نخواهد کرد،

اما مدل GRU وزن بیشتری به داده های نزدیک تر می دهد، پس احتمالا تغییرات بیشتری را در سال آینده پیش بینی می کند. و با روند فعلی تا حدودی همسو خواهند ماند.

اما مدل پایه که بدون حافظه است تا حدودی بیشترین روند تکرار شده در بازه آموزش داده شده را پیش بینی می کند.

پیش بینی هر سه نمودار از قیمت ها در سال آینده در شکل ۱۷ آمده است.