



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

درس شبکه عصبی

پاسخ تمرین شماره ششم

سید احمد رکنی حسینی - ۸۱۰۱۰۴۳۰۶

علی ممتحن - ۸۱۰۱۰۴۳۲۱

فهرست مطالب

فهرست تصاویر ۳

فهرست جداول ۴

۱ سوال یک ۵

۱—۱ تابع هزینه مدل VAE ۵

۱—۱—۱ تابع هزینه مدل جدید و عبارت نرمال‌ساز ۵

۱—۱—۲ نوع بهبود و انتخاب راه‌حل ۵

۱—۲ آشنایی با مجموعه‌داده MNIST Dynamic (پرسش ۱-۲) ۶

۱—۳ پیاده‌سازی در ابعاد نهان پایین $(d_z = 2)$ ۶

۱—۴ بررسی توزیع ابعاد نهان ۷

۱—۵ پیاده‌سازی در ابعاد نهان بالا $(d_z = 40)$ ۹

۱—۶ بررسی collapse posterior ۱۰

۱—۷ پیمایش فضای نهان ۱۰

۱—۸ نمایش شبه‌ورودی‌ها ۱۱

۱—۹ محاسبه log-likelihood ۱۱

۱—۱۰جمع‌بندی ۱۲

فهرست تصاویر

۱ نمونه‌های MNIST اصلی (سطر بالا) و MNIST Dynamic (سطر پایین) ۶

۲ مقایسه روند آموزش دو مدل در $d_z = 2$ ۷

۳ نگاشت نهان دوبعدی برای VAE استاندارد و VampPrior ۷

۴ مقایسه پیشین و پسین برای دو مدل در $d_z = 2$ ۸

۵ مقایسه منحنی‌های آموزش در $d_z = 40$ ۹

۶ مقایسه هم‌زمان حالت‌های بعد نهان پایین و بالا ۹

۷ نمونه‌های تولیدی در $d_z = 40$: سطر بالا استاندارد، سطر پایین VampPrior ۱۰

۸ پیمایش نهان مدل استاندارد در راستای مولفه اصلی اول ۱۱

۹ پیمایش نهان مدل VampPrior در راستای مولفه اصلی اول ۱۱

۱۰ سطر بالا: شبه‌ورودی‌ها، سطر پایین: خروجی دیکودر متناظر ۱۱

فهرست جداول

۱ سوال یک

۱–۱ تابع هزینه مدل VAE

در VAE هدف بیشینه‌سازی کران پایین شواهد (ELBO) است:

$$\mathcal{L}_{\text{ELBO}}(x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \,\|\, p(z)).$$

عبارت اول کیفیت بازسازی را کنترل می‌کند و عبارت KL نقش منظم‌ساز دارد

اگر KL خیلی کوچک شود مدل ممکن است اطلاعات نهان را نادیده بگیرد، و اگر خیلی بزرگ شود بازسازی افت می‌کند. بنابراین باید بین بازسازی و منظم‌سازی تعادل برقرار شود.

۱–۱–۱ تابع هزینه مدل جدید و عبارت نرمال‌ساز

در مقاله VampPrior، توزیع پیشین $\mathcal{N}(0, I)$ با یک پیشین انعطاف‌پذیر جایگزین شده است

$$p_\lambda(z) = \frac{1}{K} \sum_{k=1}^{K} q_\phi(z|u_k),$$

که u_k ها شبه‌ورودی‌های قابل یادگیری‌اند. تفاوت اصلی با VAE استاندارد این است که توزیع پیشین دیگر ساده و ثابت نیست و خود را با ساختار داده تطبیق می‌دهد؛ بنابراین فشار نامناسب KL کمتر شده و مدل نمایش نهان غنی‌تری می‌آموزد.

۱–۱–۲ نوع بهبود و انتخاب راه‌حل

اگر کیفیت خروجی پایین باشد، تحلیل مناسب این است:

- اگر RE بالا باشد (بازسازی ضعیف)، ظرفیت دیکودر/انکودر یا کیفیت داده/آموزش باید بهبود یابد.
- اگر KL غیرعادی باشد (بسیار زیاد یا بسیار نزدیک صفر)، مشکل از مدل‌سازی پیشین/پسین است و تغییر تابع هزینه (مثل VampPrior یا زمان‌بندی β) منطقی‌تر از صرفا بزرگ‌کردن شبکه است.

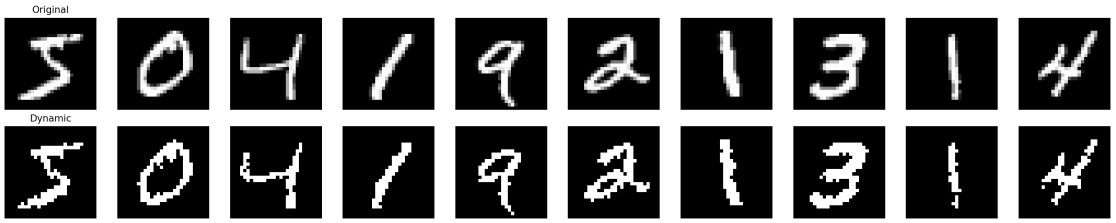
- اگر هر دو مشکل‌دار باشند، ترکیب «بهبود معماری + بهبود تابع هزینه» لازم است.

۱–۲ آشنایی با مجموعه‌داده MNIST Dynamic (پرسش ۱-۲)

Dynamic MNIST از همان تصاویر MNIST استفاده می‌کند، با این تفاوت که در هر بار استفاده، تصویر خاکستری به‌صورت تصادفی برنولی باینری‌سازی می‌شود:

$$x_{ij}^{(bin)} \sim \text{Bernoulli}(x_{ij}^{(gray)}).$$

این کار باعث می‌شود مدل مولد به جای حفظ یک نسخه باینری ثابت، توزیع داده را بهتر یاد بگیرد. در نتیجه برای آموزش VAE مناسب‌تر از Static MNIST است.



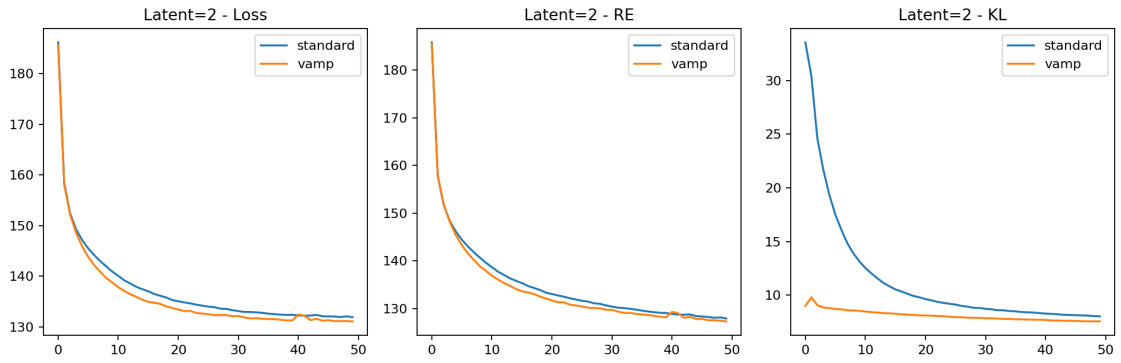
شکل ۱: نمونه‌های MNIST اصلی (سطر بالا) و MNIST Dynamic (سطر پایین)

۱–۳ پیاده‌سازی در ابعاد نهان پایین $(d_z = 2)$

دو مدل Standard VAE و VampPrior VAE با تنظیمات یکسان آموزش داده شدند. نتایج نهایی (اپاک ۵۰):

- Standard: $\text{Loss} = 131.895$، $\text{RE} = 127.876$، $\text{KL} = 8.038$
- VampPrior: $\text{Loss} = 131.068$، $\text{RE} = 127.285$، $\text{KL} = 7.565$

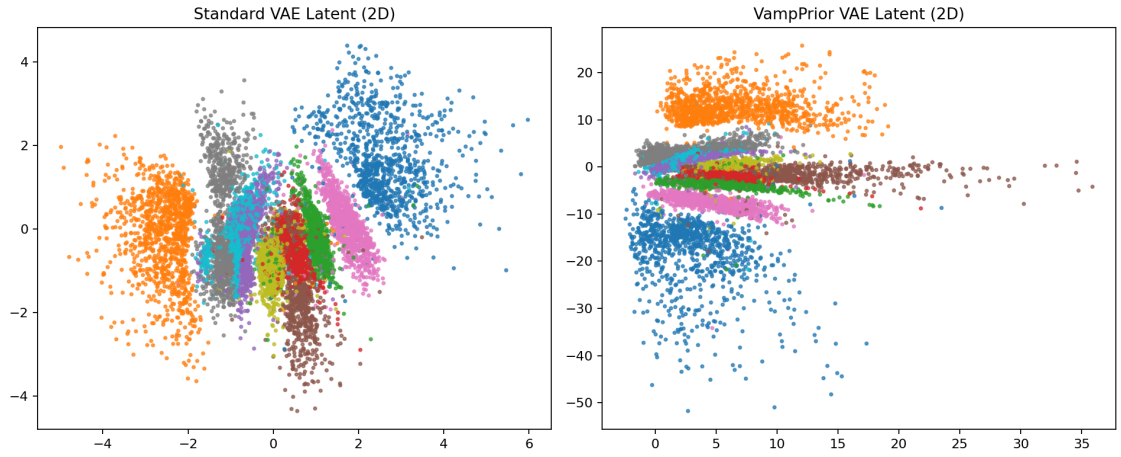
پس در بعد نهان پایین، VampPrior در هر سه معیار اندکی بهتر است.



شکل ۲: مقایسه روند آموزش دو مدل در $d_z = 2$

۱–۴ بررسی توزیع ابعاد نهان

نگاشت فضای نهان دوبعدی نشان می‌دهد هر دو مدل ساختار کلاسی را می‌آموزند، اما هندسه فضای نهان در VampPrior کشیده‌تر و ناهمسان تر است.



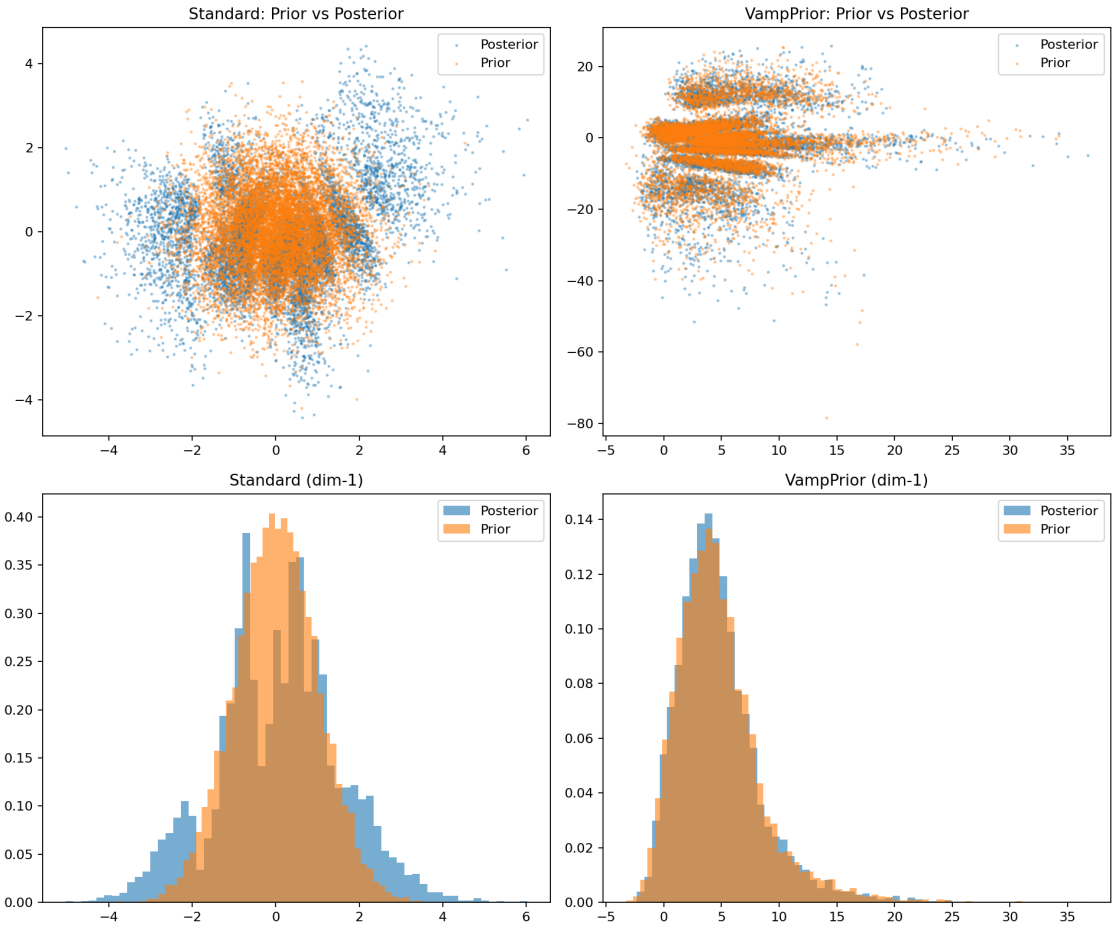
شکل ۳: نگاشت نهان دوبعدی برای VAE استاندارد و VampPrior

برای مقایسه پیشین و پسین، هم‌پوشانی تصویری در هر دو مدل قابل مشاهده است، ولی شکل توزیع‌ها متفاوت است:

- در مدل استاندارد، پیشین نزدیک نرمال استاندارد و متقارن‌تر است.

۱ سوال یک

- در VampPrior، پیشین یادگرفته‌شده چندوجهی‌تر است و با توزیع پسین روی مودهای مختلف منطبق می‌شود.



شکل ۴: مقایسه پیشین و پسین برای دو مدل در $d_z = 2$

شاخص عددی ساده‌ی moment-gap (فاصله میانگین+کوواریانس) برای این اجرا:

$$\text{Standard} = 1.490, \qquad \text{VampPrior} = 4.884.$$

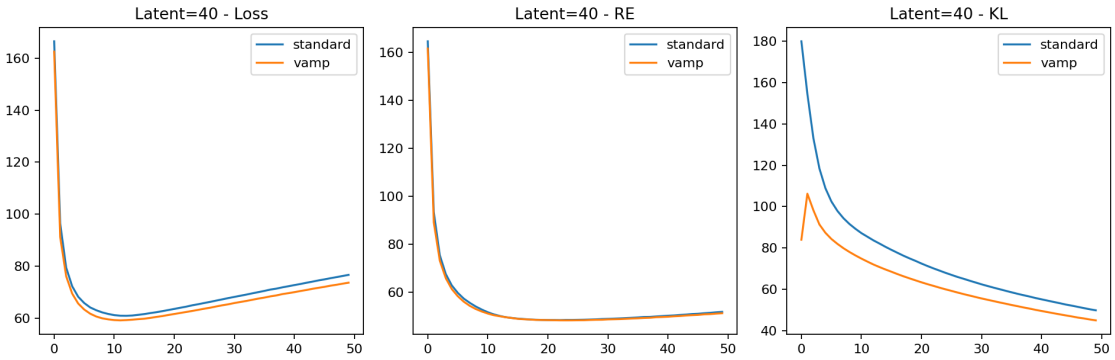
این شاخص به مقیاس و جهت‌گیری حساس است و به‌تنهایی معیار کافی برای قضاوت نهایی نیست؛ لذا تحلیل نهایی بر اساس ترکیب منحنی‌های آموزش، کیفیت نمونه‌ها و معیار IWAE انجام می‌شود.

۱–۵ پیاده‌سازی در ابعاد نهان بالا $(d_z = 40)$

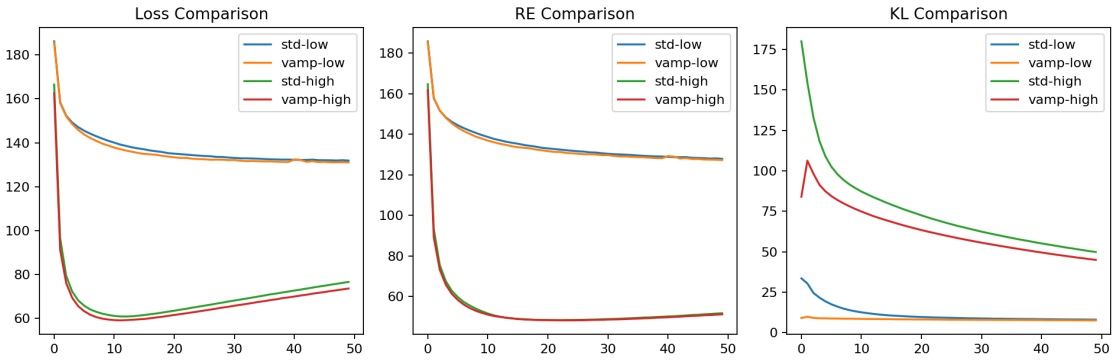
نتایج نهایی اپک ۵۰:

- Standard: $\text{Loss} = 76.658$، $\text{RE} = 51.746$، $\text{KL} = 49.824$
- VampPrior: $\text{Loss} = 73.653$، $\text{RE} = 51.175$، $\text{KL} = 44.957$

در بعد بالا نیز VampPrior در هر سه معیار بهتر است.



شکل ۵: مقایسه منحنی‌های آموزش در $d_z = 40$



شکل ۶: مقایسه هم‌زمان حالت‌های بعد نهان پایین و بالا

نمونه‌های تولیدی نیز نشان می‌دهند کیفیت خروجی VampPrior شفاف‌تر و پایدارتر از مدل استاندارد است.



شکل ۷: نمونه‌های تولیدی در $d_z = 40$: سطر بالا استاندارد، سطر پایین VampPrior

۱–۶ بررسی collapse posterior

مشکل posterior collapse به این معناست که مدل از توزیع های ورودی هیچی یاد نگیرد و همواره همان توزیع اولیه رو نگه دارد.

در این اجرا، با معیار active units (آستانه واریانس 0.01) هر دو مدل ۴۰ بعد فعال از ۴۰ بعد دارند:

$$\mathrm{AU}_{\mathrm{std}} = 40/40, \qquad \mathrm{AU}_{\mathrm{vamp}} = 40/40.$$

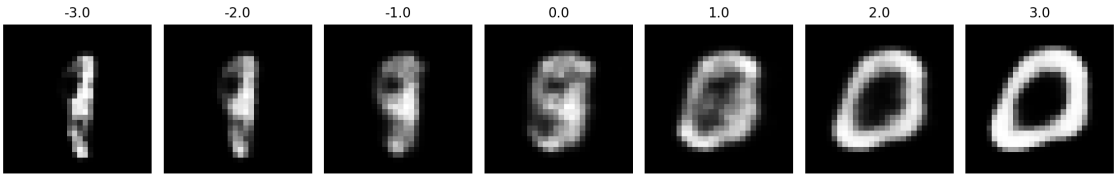
پس collapse شدید مشاهده نمی‌شود. با این حال واریانس متوسط ابعاد نهان در VampPrior بیشتر است:

$$\overline{\mathrm{Var}}_{\mathrm{std}} = 0.714, \qquad \overline{\mathrm{Var}}_{\mathrm{vamp}} = 4.600,$$

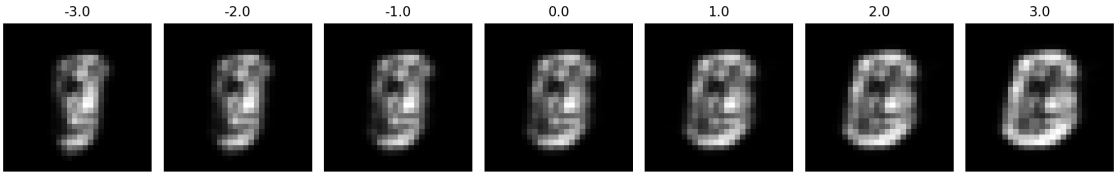
که نشان می‌دهد مدل VampPrior از فضای نهان قوی‌تر استفاده می‌کند.

۱–۷ پیمایش فضای نهان

همانطور که در درس هم دیدیم، PCA ابزاری برای بصری کردن نتایج هست که به وسیله آن می توان تغییرات معنادار در فضای نهان را مشاهده کرد. در این اجرا، پیمایش روی جهت اول PCA در فضای نهان انجام شد. در مدل استاندارد، تغییرات محدودتر است، اما در مدل VampPrior تغییرات معنایی واضح‌تری در شکل رقم دیده می‌شود (مثلا گذار نرم بین فرم‌های مختلف رقم).



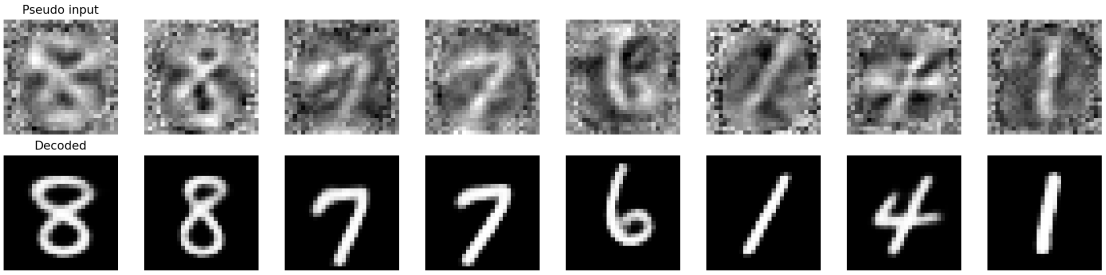
شکل ۸: پیمایش نهان مدل استاندارد در راستای مولفه اصلی اول



شکل ۹: پیمایش نهان مدل VampPrior در راستای مولفه اصلی اول

۱–۸ نمایش شبه‌ورودی‌ها

شبه‌ورودی‌ها در VampPrior الزاماً شبیه رقم تمیز نیستند، اما پس از عبور از انکودر/دیکودر، نمونه‌های معنادار (ارقام واضح) تولید می‌کنند. این دقیقا نقش مورد انتظار شبه‌ورودی‌ها در ساخت پیشین انعطاف‌پذیر را تایید می‌کند.



شکل ۱۰: سطر بالا: شبه‌ورودی‌ها، سطر پایین: خروجی دیکودر متناظر

۱–۹ محاسبه log-likelihood

معیار $\log p(x)$ در VAE به‌صورت مستقیم بهینه نمی‌شود چون انتگرال‌گیری دقیق روی z عموما intractable است. روش‌های رایج برآورد:

- Importance Sampling (IS)
- IWAE bound با K نمونه

در این پروژه از برآورد IWAE با $K = 1000$ استفاده شد:

$$\mathrm{LL}_{\mathrm{std}} = -105.544, \qquad \mathrm{LL}_{\mathrm{vamp}} = -100.616.$$

چون مقدار بزرگ‌تر (کمتر منفی) بهتر است، VampPrior عملکرد بهتری دارد. اگر معیار به‌صورت $-\log p(x)$ گزارش شود، مقادیر متناظر حدود 105.5 و 100.6 خواهند بود.

۱–۱۰ جمع‌بندی

نتایج تجربی این اجرا نشان می‌دهد VampPrior نسبت به VAE استاندارد:

- در هر دو بعد نهان پایین و بالا **Loss/RE/KL بهتری** دارد.
- **نمونه‌های باکیفیت‌تری** تولید می‌کند.
- در معیار IWAE log-likelihood بهتر است.
- **collapse شدید** ندارد و استفاده موثرتری از فضای نهان نشان می‌دهد.

بنابراین نتیجه کلی با ایده اصلی مقاله (افزایش ظرفیت پیشین برای بهبود مدل) سازگار است.